

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC (RES 020/2016 – 2024 2)		
( X ) PRÉ-PROJETO	( ) PROJETO	ANO/SEMESTRE: 2024/2

# **PROTÓTIPO PARA RECONHECIMENTO FACIAL AUTOMÁTICO DE BUGIOS- RUIVOS EM APLICAÇÕES MÓVEIS UTILIZANDO REDES NEURAIS PROFUNDAS**

Hiago Campregher

Prof. Andreza Sartori – Orientadora

Prof. Júlio César de Souza Júnior – Coorientador

## **1 INTRODUÇÃO**

A conservação da biodiversidade no Brasil enfrenta desafios significativos, e o *Alouatta guariba clamitans*, conhecido como bugio-ruivo, destaca-se como uma espécie de grande importância para a preservação da fauna da Mata Atlântica e para a saúde pública. Além de seu papel ecológico, esses primatas atuam como sentinelas na detecção de surtos de Febre Amarela, auxiliando na orientação de programas de vacinação humana em áreas fora de recomendação vacinal (Silveira, 2018).

A avaliação do risco de extinção do *Alouatta guariba* coordenada pelo ICMBio/CPB e atualizada em 2022 (ICMBio, 2022) indica que a espécie está enfrentando uma crescente ameaça devido a vários fatores. A fragmentação e a redução de seu habitat são as principais preocupações, causadas pelo desmatamento, expansão urbana, atividades agropecuárias e assentamentos rurais. A expansão urbana nas últimas décadas tem fragmentado e reduzido os habitats naturais desta espécie, expondo os animais a diversos riscos associados à urbanização, como choques elétricos, ataques de cães e atropelamentos, que têm aumentado significativamente. Além disso, a caça, a captura ilegal e as epizootias também contribuem para a ameaça. Embora a população total seja desconhecida, estima-se que existam mais de 10.000 indivíduos maduros deste táxon (ICMBio, 2022).

Em resposta a essas ameaças, o Projeto Bugio, liderado pelo Centro de Pesquisas Biológicas de Indaial (CEPESBI) e desenvolvido em parceria com a Fundação Universidade Regional de Blumenau (FURB), tem sido fundamental no monitoramento e conservação da subespécie. Criado em 1991, o CEPESBI realiza atividades de pesquisa e educação ambiental, conectando a comunidade local com estudantes e pesquisadores, além de promover a preservação do bugio-ruivo em seu ambiente natural e em cativeiro (Furb, 2021).

De acordo com Crouse *et al.* (2017), a trajetória de conservação de espécies como elefantes, grandes símios e babuínos tem sido fortalecida por pesquisas contínuas e pelo uso de tecnologias inovadoras, como o reconhecimento facial, para a identificação individual desses animais. Essa abordagem oferece uma solução não invasiva e eficiente, otimizando o monitoramento populacional ao facilitar o rastreamento de indivíduos em campo e permitindo a coleta ágil de dados. Métodos convencionais frequentemente exigem a captura e a marcação dos animais com identificadores exclusivos, como coleiras ou etiquetas, ou dependem da variação fenotípica, como cicatrizes e padrões de pelagem. Além disso, essa dependência exige que os pesquisadores possuam um conhecimento aprofundado dessas características para diferenciar os indivíduos. O reconhecimento facial, por sua vez, elimina a necessidade de capturas repetidas, proporcionando uma alternativa eficaz para estudos longitudinais de primatas.

Diante disso, este trabalho tem como objetivo aprimorar o modelo de reconhecimento e detecção facial de bugios-ruivos, tornando-o mais rápido e preciso, de modo a disponibilizar um protótipo de aplicação móvel para uso em campo. Este trabalho dará continuidade ao estudo de Maschio (2022), que desenvolveu um protótipo de reconhecimento individual de bugios-ruivos. Com isso, este trabalho visa melhorar o processo de reconhecimento e detecção individual dos bugios-ruivos por meio de modelos de aprendizado profundo otimizados para dispositivos móveis, reduzindo o tempo de campo e os erros de amostragem, além de otimizar a coleta de dados. Ao implementar essas melhorias, espera-se contribuir para a conservação da espécie e para o avanço do conhecimento científico sobre o bugio-ruivo.

### **1.1 OBJETIVOS**

O objetivo deste trabalho é disponibilizar um protótipo de aplicação móvel capaz de realizar a identificação facial individual de bugios-ruivos a partir de imagens utilizando redes neurais profundas, dando continuidade ao trabalho de Maschio (2022).

Os objetivos específicos são:

- incluir um modelo computacional para a detecção e reconhecimento facial individual dos primatas em aplicação móvel;
- estruturar a infraestrutura que irá integrar o modelo computacional de identificação facial junto ao

- protótipo;
- c) validar a precisão e eficácia do modelo de rede neural profunda selecionado;
- d) validar a funcionalidade e usabilidade do protótipo em campo, em colaboração com os pesquisadores do Projeto Bugio.

## 2 TRABALHOS CORRELATOS

Esta seção descreve os trabalhos que se assemelham aos objetivos propostos por este projeto. A subseção 2.1 aborda o processo de revisão sistemática, detalhando desde a pesquisa inicial até a seleção dos trabalhos relevantes. Em seguida, a subseção 2.2 fornece uma análise detalhada dos trabalhos correlatos selecionados.

### 2.1 REVISÃO SISTEMÁTICA

O processo de busca dos trabalhos correlatos fundamentou-se em pesquisar nos seguintes portais, Google Acadêmico, ResearchGate, Biblioteca Digital da FURB e ScienceDirect. Para garantir a abrangência e qualidade da revisão, foi utilizada uma *string* de busca com diferentes combinações dos termos relacionados ao tema central do estudo, conforme pode ser observado no Quadro 1. Sendo ela composta pelos termos: o primeiro (“*Facial Recognition*”), o segundo (“*Howler Monkeys*” OR “*Monkeys*” OR “*Primates*” OR “*Chimpanze*”), o terceiro (“*Mobile*” OR “*Applications*” OR “*App*”) e por fim, o quarto (“*Deep Neural Networks*” OR “*Deep Learning*” OR “*Convolutional Neural Networks*” OR “*MobileNet*” OR “*SqueezeNet*” OR “*FaceNet*”).

Quadro 1– Resultado de buscas dos termos em artigos

String de busca	Google Acadêmico	ResearchGate	Biblioteca Digital da FURB	ScienceDirect
("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates") AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App") AND ("Deep Neural Networks" OR "Deep Learning" OR "CNN" OR "Convolutional Neural Networks" OR "MobileNet" OR "SqueezeNet" OR "EfficientNet" OR "FaceNet" OR "DeepFace"))	924	13520	-	-
("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates" OR "Animals") AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App") AND ("Deep Neural Networks" OR "Deep Learning" OR "CNN" OR "Convolutional Neural Networks" OR "MobileNet" OR "SqueezeNet" OR "EfficientNet" OR "FaceNet" OR "DeepFace"))	7300	13520	-	-
("Facial Recognition" AND ("Primates" OR "Macacos" OR "Primates" OR "Bugio" OR "Chimpanze" OR "Primates" OR "Howler monkey" OR "Monkey") AND ("Simple" OR "Lightweight" OR "Basic") AND ("Neural Networks" OR "CNN" OR "Convolutional Neural Networks") AND ("Mobile" OR "Application" OR "App"))	1850	39180	-	-
("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates") AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App"))	4840	77570	-	366

Fonte: elaborado pelo autor (2024).

A estratégia de busca foi estruturada com o objetivo de encontrar trabalhos que apresentassem características semelhantes ao foco e aos objetivos deste trabalho, abrangendo diferentes abordagens metodológicas e resultados relevantes. O período de publicação dos artigos considerados foi estabelecido entre os

anos de 2018 e 2024, com preferência aos mais atuais, no intuito de garantir a pertinência das fontes revisadas. Os trabalhos que não atendiam as características principais do trabalho proposto foram desconsiderados.

Para selecionar os trabalhos mais relevantes, foram aplicados critérios de inclusão, detalhados na Tabela 1, com pesos atribuídos variando entre um e três. A inclusão ou exclusão dos artigos foi realizada com base nas palavras-chave e leitura parcial dos textos. Um trabalho foi considerado elegível ao atingir ou superar a pontuação total de 10 pontos. Na seleção final, foram priorizados os trabalhos do Quadro 2 com as maiores pontuações.

Tabela 1 – Critérios de Inclusão dos Trabalhos Correlatos

ID	Critérios de Inclusão	Peso
1	Solução com reconhecimento em tempo real	3
2	Solução com detecção automática de faces	2
3	Solução com identificação facial individual	3
4	Solução relacionada a reconhecimento de primatas	1
5	Solução aplicada em dispositivos móveis	2
6	Estudo publicado nos últimos 6 anos	1
7	Disponibilidade e metodologia completa	3
	Total	15

Fonte: elaborado pelo autor (2024).

O Quadro 2 apresenta os trabalhos correlatos que atenderam aos critérios definidos.

Quadro 2 - Síntese dos trabalhos correlatos selecionados

Assunto	Filtro	Pontuação Total	Referência
Automatic Identification of Individual Primates with Deep Learning Techniques	("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates")) AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App") AND ("Deep Neural Networks" OR "Deep Learning" OR "CNN" OR "Convolutional Neural Networks" OR "MobileNet" OR "SqueezeNet" OR "EfficientNet" OR "FaceNet" OR "DeepFace"))	12	Guo <i>et al.</i> (2020)
SheepFaceNet: A Speed-Accuracy Balanced Model for Sheep Face Recognition	("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates" OR "Animals")) AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App") AND ("Deep Neural Networks" OR "Deep Learning" OR "CNN" OR "Convolutional Neural Networks" OR "MobileNet" OR "SqueezeNet" OR "EfficientNet" OR "FaceNet" OR "DeepFace"))	12	Li <i>et al.</i> (2023)
Face Recognition: Primates in the Wild	("Facial Recognition" AND ("Primates" OR "Macacos" OR "Primates" OR "Bugio" OR "Chimpanze" OR "Primates" OR "Howler monkey" OR "Monkey")) AND ("Simple" OR "Lightweight" OR "Basic") AND ("Neural Networks" OR "CNN" OR "Convolutional Neural Networks") AND ("Mobile" OR "Application" OR "App"))	13	Deb <i>et al.</i> (2018)
Deep learning for automatic facial detection and recognition in Japanese macaques: illuminating social networks	("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates")) AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App") AND ("Deep Neural Networks" OR "Deep Learning" OR "CNN" OR "Convolutional Neural Networks" OR "MobileNet" OR "SqueezeNet" OR "EfficientNet" OR "FaceNet" OR "DeepFace"))	13	Paulet <i>et al.</i> (2024)
Real-time goat face recognition using convolutional neural network	("Facial Recognition" AND ("Howler Monkeys" OR "Monkeys" OR "Primates")) AND ("Mobile" OR "Application" OR "Mobile Applications" OR "App") AND ("Deep Neural Networks" OR "Deep Learning" OR "CNN" OR "Convolutional Neural Networks" OR "MobileNet" OR "SqueezeNet" OR "EfficientNet" OR "FaceNet" OR "DeepFace"))	11	Billah <i>et al.</i> (2022)

Fonte: elaborado pelo autor (2024).

## 2.2 SÍNTESE DOS TRABALHOS CORRELATOS

Nesta subseção, são apresentados os trabalhos com maior correlação ao estudo proposto. O Quadro 3 apresenta o trabalho de Paulet *et al.* (2024), que desenvolveu um pipeline automático para detectar, reconhecer e construir a estrutura social da população de macacos japoneses com base nas suas interações utilizando aprendizado profundo. No Quadro 4, detalha o estudo de Deb *et al.* (2018), no qual é desenvolvido e avaliado um método de reconhecimento facial para espécies de primatas ameaçadas. Esse método utiliza uma arquitetura de rede neural convolucional denominada PrimNet, projetada especificamente para esse propósito. Além disso, foi desenvolvido um aplicativo Android para auxiliar pesquisadores na identificação dos animais em campo. Ao final,

no Quadro 5, é descrito o trabalho de Li *et al.* (2023), que propõem um algoritmo para reconhecimento facial de ovelhas utilizando MobileNet para redução de recursos computacionais.

No Quadro 3 é resumido o trabalho de Paulet *et al.* (2024), no qual o foco é a criação de um *pipeline* automatizado composto por três etapas principais: detecção facial, reconhecimento dos indivíduos e análise da rede social. O processo abrange desde extrair os quadros de vídeo até o reconhecimento individual, além de analisar a rede social dos macacos buscando inferir conexões e posições hierárquicas. O pipeline é compartilhado através do Google Colab, permitindo que possa ser ajustado o modelo com novos conjuntos de dados.

O trabalho de Paulet *et al.* (2024) será utilizado como referência devido à sua estrutura completa para a detecção e reconhecimento individual de primatas, contando com tecnologias atuais, como o modelo de reconhecimento YOLOv8, que apresentou bons resultados em termos de precisão e eficiência. Além disso, a abordagem de utilizar a ferramenta para analisar as interações sociais, permite ampliar as possibilidades dos estudos comportamentais e ecológicos em prol da conservação das espécies.

Quadro 3 – Deep learning for automatic facial detection and recognition in Japanese macaques: illuminating social networks

Referência	Paulet <i>et al.</i> (2024)
Objetivos	Detecção e identificação individual de macacos japoneses em vídeos.
Principais funcionalidades	Aplicar um modelo de rede neural convolucional, chamado Faster-RCNN para detectar a face de macacos japoneses, junto a um modelo de reconhecimento YOLOv8 para reconhecer individualmente esses primatas. O conjunto de dados utilizado para a detecção facial é composto por 17.722 imagens, das quais 92% foram destinadas ao treinamento e o restante para validação. O conjunto de dados para o classificador é composto por 5.956 imagens, sendo 87% usadas para treinamento e o restante para validação.
Ferramentas de desenvolvimento	Rede Neural Convolucional (CNN), Arquitetura Faster R-CNN e Backbone ResNet-50, Métricas IoU e AP50, Detectron 2, YOLOv8 e Google Colab.
Resultados e conclusões	O modelo de detecção facial atingiu uma precisão de 82,2% e reduziu a taxa de falsos negativos para 13,65%. De maneira similar, o classificador para identificação individual alcançou uma precisão de Top1 de 83% e de Top5 de 92,92%.

Fonte: elaborado pelo autor (2024).

No Quadro 4 é feita uma síntese referente ao trabalho de Deb *et al.* (2018), que destaca uma arquitetura de rede neural artificial desenvolvida para a identificação de primatas, particularmente em condições com conjuntos de dados reduzidos e em tempo real. No entanto, o modelo exige a anotação manual de pontos de referência, como olhos e boca, nas imagens, o que pode ser um desafio em ambientes não controlados. Portanto, soluções que utilizam técnicas de detecção de objetos, semelhantes às utilizadas no trabalho do Quadro 3, podem ser complementares.

O trabalho de Deb *et al.* (2018) será adotado como referência a este trabalho por sua arquitetura precisa, eficiente e compatível com dispositivos móveis, alinhando-se com a proposta deste trabalho. Além disso, o modelo PrimNet demonstrou bons resultados em reconhecer diferentes espécies de primatas, o que sugere uma boa adaptação a novas espécies.

Quadro 4 – Face Recognition: Primates in the Wild

Referência	Deb <i>et al.</i> (2018)
Objetivos	Identificação individual de primatas usando reconhecimento facial automático.
Principais funcionalidades	Aplicar um modelo de rede neural convolucional, denominada PrimNet, para o reconhecimento individual de espécies de primatas em um aplicativo móvel Android. O desempenho do modelo foi avaliado utilizando três conjuntos de dados de primatas: LemurFace, GoldenMonkeyFace e ChimFace, em três diferentes tarefas: verificação, identificação em um conjunto de dados que não é garantido que haja uma correspondência ao indivíduo sendo identificado, identificação em um conjunto de dados com garantia de correspondência ao indivíduo sendo identificado.
Ferramentas de desenvolvimento	Rede Neural Convolucional (CNN) e PrimNet.
Resultados e conclusões	Os resultados obtidos demonstram a eficácia do modelo em diferentes cenários, com uma taxa de aceitação na verificação de 83,11%, a precisão na identificação de um primata é de 93,76% quando se sabe que ele está no banco de dados. No entanto, essa precisão diminui para 81,73% ao tentar identificar um primata cuja presença no banco de dados não é garantida, o que pode resultar em sua não identificação. Além disso, o PrimNet apresentou um tamanho de armazenamento de apenas 3.9 MB e uma velocidade de inferência de 24ms por imagem, tornando-o uma solução adequada para sistemas embarcados.

Fonte: elaborado pelo autor (2024).

No Quadro 5 é apresentado o trabalho de Li *et al.* (2023), que introduz o SheepFaceNet, um modelo desenvolvido para o reconhecimento e detecção de faces de ovelhas com alta precisão e velocidade, enquanto mantém um baixo consumo de recursos computacionais. Isso torna o modelo ideal para aplicações em tempo real e em dispositivos móveis. Também, como o próprio estudo sugere o modelo pode ser adaptado para outras espécies, como primatas, o que abre possibilidade para ampliar sua relevância.

O trabalho de Li *et al.* (2023) servirá de base para o trabalho proposto devido à sua abordagem adotada com o SheepFaceNet, um modelo desenvolvido exclusivamente para o reconhecimento de ovelhas com melhorias específicas, o que indica um potencial formato para melhorar o reconhecimento facial dos bugios-ruivos. Além disso, a arquitetura conta com um modelo para detecção de faces que otimiza o processo de reconhecimento ao focar nas características mais relevantes das imagens, mitigando problemas relacionados às condições do ambiente em que a face está inserida.

### 3 PROTÓTIPO ATUAL

O protótipo desenvolvido por Maschio (2022) é um sistema que aplica o modelo treinado para o reconhecimento facial em novas imagens de bugios-ruivos. Este sistema pode funcionar como um aplicativo ou como um sistema integrado em dispositivos móveis, sendo capaz de processar e identificar imagens em tempo real ou a partir de arquivos. A Figura 1(a), apresenta a tela principal da aplicação, que inclui uma interface para o upload de imagens, a exibição dos resultados de reconhecimento e, possivelmente, a adição de novas imagens ao banco de dados. Ao clicar no botão de `Prever Classe`, o sistema realiza a previsão e exibe o nome do bugio reconhecido junto com a porcentagem de confiança daquele resultado (Figura 1(b)).

Como trabalhos futuros, Maschio (2022) sugere a integração do modelo na nuvem, permitindo atualizações contínuas e a adição de novas classes, como novos bugios, sem a necessidade de novas versões do aplicativo. Maschio (2022) relata ainda que o protótipo enfrenta algumas limitações no reconhecimento facial, especialmente com imagens de faces inclinadas ou com variações na iluminação. Para melhorar a precisão, seria necessário fornecer imagens recortadas que contenham apenas a face do bugio. Uma solução para essas limitações é o uso de outra CNN dedicada à detecção de faces, o que poderia oferecer maior flexibilidade na captura das imagens.

#### 4 PROPOSTA

Esta seção apresenta a proposta do desenvolvimento de um protótipo de aplicativo móvel para reconhecimento facial automático de bugios-ruivos, utilizando redes neurais profundas. A justificativa para essa solução é discutida, assim como a metodologia que será adotada para sua implementação.

##### 4.1 JUSTIFICATIVA

No Quadro 6 é descrito um comparativo entre os trabalhos correlatos. As linhas representam as características e as colunas os trabalhos.

Quadro 6 - Comparativo dos trabalhos correlatos

Trabalhos Correlatos Características	Paulet <i>et al.</i> (2024)	Deb <i>et al.</i> (2018)	Li <i>et al.</i> (2023)
Reconhecimento em tempo real	Sim	Sim	Sim
Modelo para detecção automática de faces	Faster R-CNN, backbone ResNet-50	-	SheepFaceNetDet (RetinaFace e Eblock)
Modelo para reconhecimento facial	Yolo v8 Nano	PrimNet	MobileNet
Animal reconhecido	Macaco-japonês	Lêmure, macaco-dourado e chimpanzé	Ovelha
Interface com o Usuário	Web – Google Colab	Dispositivo móvel	Câmeras inteligentes e outros sistemas embarcados
Precisão do modelo	82,2%	A precisão na identificação de um primata é de 93,76% quando se sabe que ele está no banco de dados. No entanto, essa precisão diminui para 81,73% ao tentar identificar um primata cuja presença no banco de dados não é garantida, o que pode resultar em sua não identificação.	97,75%
Total de imagens utilizadas	17.772	10.009	16.812

Fonte: elaborado pelo autor (2024).

Conforme o Quadro 6, todos os trabalhos correlatos utilizaram Redes Neurais Convolucionais para o reconhecimento facial. Deb *et al.* (2018) diversificou seu modelo para outras espécies de primatas, como lêmures, macacos-dourados e chimpanzés, além disso testou sua abordagem em um dispositivo móvel, alinhando-se ao objetivo deste trabalho de disponibilizar um protótipo para dispositivos móveis. Outro aspecto relevante é que todos os estudos mencionados implementaram reconhecimento facial individual em tempo real, uma característica essencial para o trabalho atual.

Em relação aos modelos para reconhecimento, Li *et al.* (2023) utilizou MobileNet, pois esse modelo demonstrou ser leve e eficiente, tornando-o adequado para dispositivos com recursos limitados. Deb *et al.* (2018) optou por PrimNet devido à configuração de sua arquitetura, projetada especificamente para primatas. Embora seu trabalho não mencione diretamente preocupações com recursos limitados, fica evidente o funcionamento do modelo ao testá-lo diretamente em um dispositivo móvel. Já Paulet *et al.* (2024) utilizou YOLOv8 em função dos resultados satisfatórios apresentados no reconhecimento, no entanto, seu estudo não demonstra preocupação com os recursos computacionais, o que pode tornar o modelo inadequado para dispositivos móveis.

Paulet *et al.* (2024) e Li *et al.* (2023) adotaram técnicas avançadas visando a detecção rápida e precisa de faces. Paulet *et al.* (2024) empregou um modelo de Faster R-CNN que busca regiões candidatas em que as faces podem estar localizadas, utilizando a arquitetura Backbone ResNet-50 para extrair características complexas das imagens. Li *et al.* (2023) desenvolveu um modelo próprio projetado e otimizado para identificar os rostos de ovelhas, denominado SheepFaceNetDet, composto por RetinaFace para identificação em diferentes escalas e condições e Eblock, uma arquitetura otimizada para melhorar a eficiência do processamento em redes neurais. Por outro lado, Deb *et al.* (2018) não utilizou técnicas para a detecção facial automática, necessitando que a marcação de pontos faciais fosse feita manualmente, o que pode ser um fator limitante em aplicações práticas.

Li *et al.* (2023) alcançou uma precisão de 97,75%, demonstrando a eficácia do seu modelo em um cenário otimizado. Deb *et al.* (2018) apresentou uma precisão de 93,76% em situações em que a amostra estava presente, mas caiu para 81,73% em contextos que a amostra poderia não estar presente. Paulet *et al.* (2024) obteve uma precisão de 82,2%, que, embora inferior, ainda representa um desempenho aceitável para o reconhecimento em tempo real e ambiente não controlado.

Diante dessas características, pode-se afirmar que o uso de redes neurais profundas para detecção e reconhecimento facial de primatas é eficaz e aplicável em dispositivos móveis. A proposta deste trabalho se diferencia ao focar especificamente nos bugios-ruivos, uma espécie com um contexto de conservação particular, enquanto Paulet *et al.* (2024) e Deb *et al.* (2018) abrangeram espécies de primatas em geral, e Li *et al.* (2023) ovelhas. Além disso, o protótipo móvel proposto visa equilibrar precisão e eficiência, sendo aplicável em cenários reais de conservação, onde há limitações de tempo e recursos, proporcionando uma solução prática para o reconhecimento facial em campo.

Este trabalho, busca aprofundar o conhecimento sobre o uso de redes neurais profundas aplicadas à identificação individual de bugios-ruivos, considerando características faciais. Propõe um protótipo móvel que atenda às exigências de campo ao equilibrar precisão e eficiência. Além disso, o trabalho proposto dá continuidade ao trabalho de Maschio (2022), ampliando a abordagem com a aplicação de novas técnicas e explorando novas possibilidades para melhorar a eficiência do reconhecimento facial.

## 4.2 METODOLOGIA

O trabalho será desenvolvido observando as seguintes etapas:

- a) levantamento bibliográfico: realizar levantamento bibliográfico sobre bugios-ruivos, algoritmos e modelos para detecção e identificação facial direcionados para dispositivos móveis, redes neurais profundas, bem como trabalhos correlatos;
- b) coleta e atualização da base de dados: coletar e preparar as imagens de bugios-ruivo para uso do modelo;
- c) submissão de requerimento ao Comitê de Ética: submeter o requerimento ao Comitê de Ética da FURB para utilizar as imagens de animais;
- d) elicitação de requisitos: com base no levantamento bibliográfico reavaliar os requisitos propostos para o protótipo;
- e) seleção das arquiteturas: definir as arquiteturas que vão ser utilizadas como base para os modelos;
- f) desenvolvimento do modelo de identificação facial: definir e implementar o modelo de Aprendizado de Máquina e Visão Computacional mais adequado para extrair as características, treinar e classificar os indivíduos;
- g) teste e validações do modelo: verificar a precisão do modelo desenvolvido e o uso de recursos adequado para dispositivos móveis, utilizando métricas de F1-Score, Precision, Recall e latência;
- h) definição de requisitos: definir os requisitos e especificações necessárias para a aplicação móvel;
- i) desenvolvimento do protótipo: integrar o modelo implementado a um protótipo para dispositivos móveis desenvolvido em Flutter;
- j) criação da infraestrutura para publicação: criar a infraestrutura necessária para a publicação do protótipo, integrada à arquitetura de reconhecimento;
- k) validação: validar a funcionalidade e usabilidade do protótipo em colaboração com um responsável do Projeto Bugio para comprovar os resultados obtidos.

## 5 REVISÃO BIBLIOGRÁFICA

Esta seção descreve os conceitos que fundamentam este trabalho, estruturados da seguinte forma: na subseção 5.1, discorre-se sobre o bugio-ruivo; na subseção 5.2, aborda-se detecção e reconhecimento facial; na subseção 5.3, trata-se da rede neural profunda.

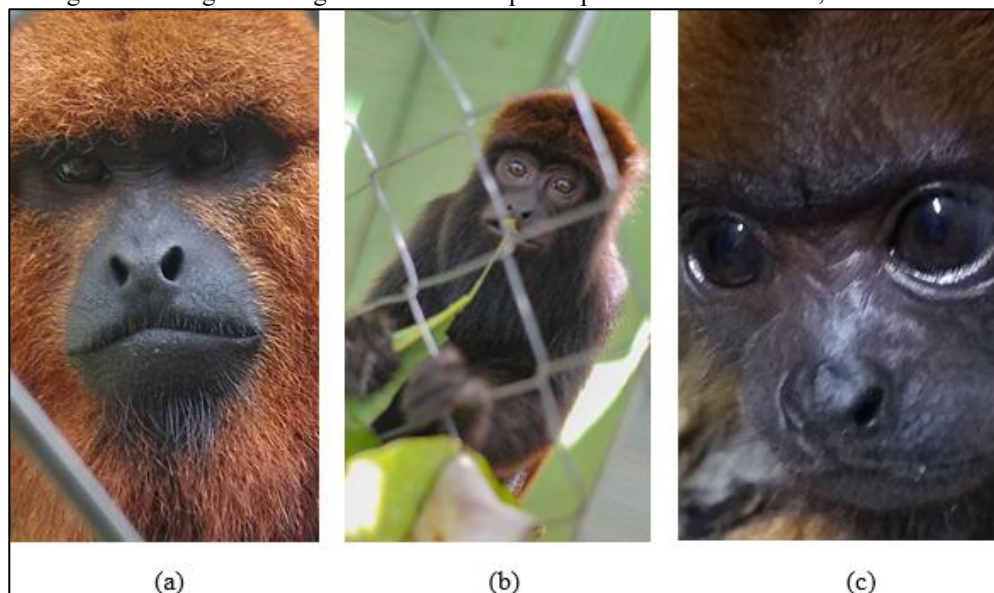
### 5.1 BUGIO-RUIVO

Auricchio (1995) descreve os primatas do gênero *Alouatta*, conhecidos no Brasil como guaribas, barbados ou gritadores, como animais arbóreos, com um corpo robusto e uma pelagem densa, destacando a presença de uma

barba espessa sob a face nua, que possui pele negra. Entre os membros dessa espécie, encontra-se o bugio-ruivo que se destaca pelo desenvolvido do osso hióide, uma estrutura que pode ser de até 50% maior nos machos em comparação às fêmeas (Gregorin, 2006). De acordo com Sartore (2022), os bugios possuem uma cauda preênsil, que atua como um “braço extra” para se pendurar em galhos, visto que esses primatas raramente descem ao solo, preferindo permanecer no alto das árvores, onde se alimentam de folhas.

Além disso, os machos e as fêmeas apresentam dicromatismo sexual na pelagem, conforme pode ser observado na Figura 2, em que a coloração dos machos adultos (Figura 2 (a)) varia entre avermelhada, castanho-avermelhada e ruiva (Gregorin, 2006). A pigmentação ruiva é atribuída a secreções de glândulas produtoras de pigmentos, distribuídas em várias regiões do corpo. Hirano *et al.* (2003) sugerem que o grau de rufosidade pode estar relacionado à idade e à posição hierárquica dentro do grupo. Por sua vez, fêmeas adultas (Figura 2 (b)) e jovens de ambos os sexos (Figura 2 (c)) apresentam uma pelagem enegrecida (Gregorin, 2006).

Figura 2 – Imagem de bugios-ruivos: da esquerda para a direita – macho, fêmea e bebê



Fonte: elaborado por Maschio (2022).

Em relação ao tamanho, as fêmeas possuem um comprimento cabeça-corpo que varia de 390 a 575 mm, com caudas medindo entre 490 e 710 mm, de acordo com os dados coletados por Chiarelli (1972). Redford e Eisenberg (1992) indicam uma média de 494 mm para o comprimento cabeça-corpo, baseada em dez indivíduos, e uma média de 459 mm para a cauda no mesmo grupo de estudo. Os machos adultos tendem a ser maiores, com um comprimento cabeça-corpo variando entre 465 e 720 mm e um comprimento da cauda que varia de 490 a 750 mm, segundo Chiarelli (1972). Estudos de Redford e Eisenberg (1992) sugerem uma média de 550 mm para o comprimento cabeça-corpo e 452 mm para a cauda. Além disso, Machado *et al.* (2014) reportaram uma média de 537 mm para o comprimento cabeça-corpo, com desvio padrão de 78 mm e variação entre 450 e 600 mm, além de uma média de 613 mm para o comprimento da cauda, com desvio padrão de 23 mm e variação de 600 a 640 mm, com base em três indivíduos.

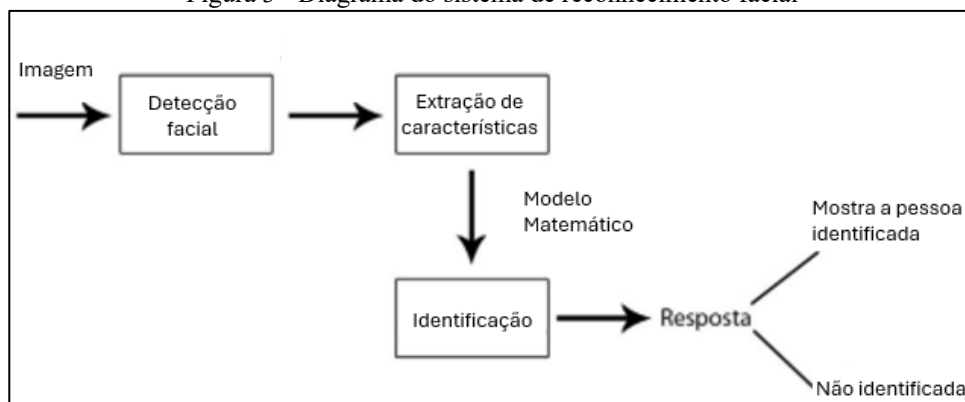
## 5.2 RECONHECIMENTO FACIAL

O reconhecimento facial é uma técnica utilizada para identificar indivíduos por meio de algoritmos de visão computacional que analisam e automatizam tarefas de percepção visual, envolvendo imagens e processos complexos para distinguir padrões, assim como o aprendizado humano (Pires, 2023). De acordo com Cordeiro *et al.* (2023), o reconhecimento facial busca mapear o rosto com base em padrões geométricos e logarítmicos, analisando características únicas, como a distância entre os olhos, o formato do rosto e a estrutura do queixo e nariz, entre outras. Cordeiro *et al.* (2023) afirmam que essas características são comparadas com as já armazenadas em um banco de dados para realizar a identificação.

Aguiar *et al.* (2019) ressaltam que, embora frequentemente confundidas, detecção e reconhecimento facial são áreas distintas: a detecção apenas busca encontrar a presença de uma face em imagens ou vídeos, enquanto o reconhecimento vai além, determinando quem é o indivíduo. Aguiar *et al.* (2019) ainda explicam que o reconhecimento facial envolve várias etapas, conforme ilustrado na Figura 3. A primeira etapa é a detecção, que elimina informações irrelevantes, focando apenas na face. Posteriormente, ocorre a extração das características, onde os traços faciais são coletados. Por fim, um modelo para identificação é aplicado, resultando na identificação ou não do indivíduo.



Figura 3 - Diagrama do sistema de reconhecimento facial



Fonte: adaptado de (Kemerich & Martins, 2021).

Além disso, Amjad *et al.* (2023) destacam que a aplicação de reconhecimento facial não se limita a uma área do conhecimento. Segundo Amjad *et al.* (2023), a tecnologia de reconhecimento facial desempenha um papel importante para o avanço do estudo do comportamento e da ecologia animal. O uso de algoritmos para identificar e rastrear indivíduos com base em características faciais únicas, oferece um método não invasivo e econômico para o monitoramento e conservação da vida selvagem. Contudo, Amjad *et al.* (2023) apontam limitações, como tamanhos de amostra pequenos e ambientes controlados, que podem não refletir as condições naturais da vida selvagem.

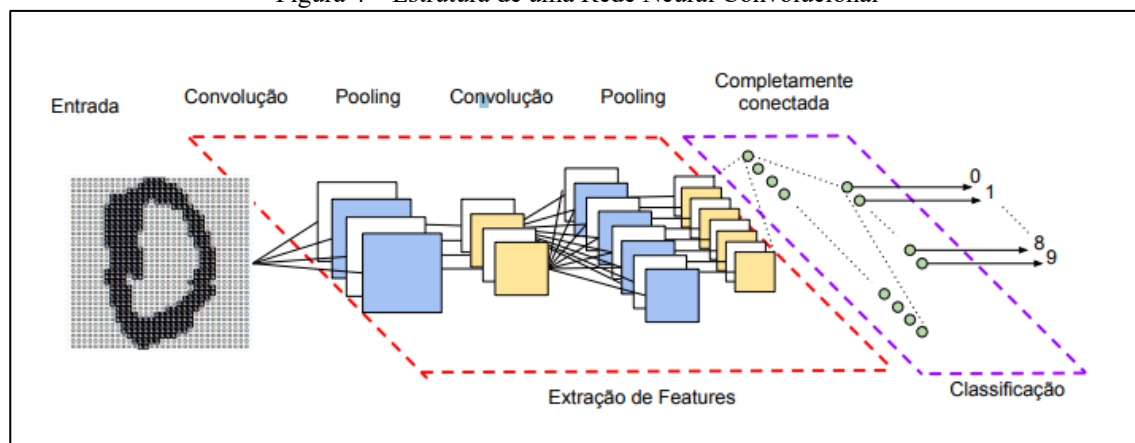
### 5.3 REDES NEURAIS PROFUNDAS

As redes neurais profundas (DNNs) representam uma abordagem dentro do aprendizado de máquina, um método de análise de dados que automatiza o desenvolvimento de modelos analíticos (Sharifani e Amini, 2023). Segundo Russell (2022), o aprendizado profundo originou-se de estudos pioneiros que buscaram modelar redes de neurônios artificiais, orientados nas propriedades fisiológicas de um neurônio cerebral (McCulloch e Pitts, 1943, apud Russell, 2022), usando circuitos computacionais. Por essa razão, redes treinadas com técnicas de aprendizado profundo são comumente chamadas de redes neurais, embora a semelhança com neurônios e estruturas cerebrais reais seja apenas superficial Russell (2022).

Originalmente, as redes neurais eram compostas por até três camadas neurais. Contudo, com o avanço das pesquisas, essas redes tornaram-se cada vez mais complexas, passando a incluir mais camadas. Sendo assim, redes com mais de três camadas passaram a ser conhecidas como redes neurais profundas. Essa estrutura é amplamente aplicada em áreas como processamento de imagens e visão computacional, onde as Redes Neurais Convolucionais (CNNs) que são um subtipo de DNN se destacam como as mais comuns de serem utilizadas (LeCun, Bengio, e Hinton, 2015).

As Redes Neurais Convolucionais são uma variação dos Perceptrons de Múltiplas Camadas. As CNNs aplicam filtros sobre os pixels de uma imagem, preservando as relações de proximidade da imagem ao longo do processamento. A arquitetura desta rede é caracterizada pela presença de camadas iniciais de convolução e pooling, de modo geral, conforme ilustrado na Figura 4 a rede, inclui uma camada de entrada, seguida por uma ou mais sequências de camadas convolucionais e de pooling, culminando em um conjunto de camadas totalmente conectadas e associadas a uma função de custo, frequentemente acompanhada por técnicas de regularização. A arquitetura de uma CNN pode variar em termos de ordem, tipos de camadas, funções de ativação e quantidade de elementos (Vargas, Carvalho, Vasconcelos, 2016). Além disso, conforme destacado por Gu *et al.* (2017), variações como as redes ResNet, que introduzem conexões residuais para evitar o problema do gradiente desaparecendo em redes profundas, e a Inception, que utiliza múltiplos filtros de convolução para capturar diferentes escalas de características em uma única camada, ampliam a capacidade das CNNs, tornando-as mais eficientes e adaptáveis a diferentes desafios de visão computacional.

Figura 4 – Estrutura de uma Rede Neural Convolucional



Fonte: elaborada por (Vargas, Carvalho, Vasconcelos, 2016).

De acordo com Goldbarg (2024), as técnicas de aprendizado profundo têm sido eficazes na solução de diversos problemas. Guo *et al.* (2020) enfatizam que as redes neurais são aptas a lidar com problemas reais, que não apresentam uma relação direta, devido à sua capacidade de extrair e aprender as características dos dados de entrada. No entanto, elas exigem um esforço computacional significativo devido à quantidade de operações e parâmetros envolvidos. Isso pode ser um desafio, especialmente em aplicações com recursos computacionais limitados. Para mitigar esse problema, Goldbarg (2024) ressalta que existem alternativas, como o processamento paralelo, a compressão de modelos, a exploração da esparsidade e a redução dos modelos por aproximação.

Conforme Junior *et al.* (2022), a avaliação dos resultados das redes neurais e outros algoritmos de inteligência artificial dependem de métricas apropriadas para assegurar sua eficiência e confiabilidade. Entre as métricas fundamentais estão a acurácia, que indica a proporção de previsões corretas, a precisão, que relaciona os verdadeiros positivos e os casos classificados como positivos, e a sensibilidade, que mede a capacidade de identificar corretamente os casos positivos. Além disso, há métricas como o F1-Score que visa equilibrar precisão e sensibilidade. Junior *et al.* (2022) enfatiza que o uso de múltiplas métricas auxilia para capturar diferentes perspectivas do desempenho do modelo e evitar interpretações limitadas.

## REFERÊNCIAS

- AGUIAR, Wellington Sousa *et al.* Detecção e reconhecimento facial utilizando javacv e o algoritmo LBPH. In: **16th International Conference on Information Systems & Technology Management**, 2019. Disponível em: <https://www.tecsi.org/contecsi/index.php/contecsi/16CONTECSI/paper/download/6039/3471>. Acesso em: 19 set. 2024.
- AMJAD, Muhammad *et al.* **Animal facial detection for individual identification of animals using machine learning**, v. 2, n. 2, jun. 2023. Disponível em: <https://jncbae.com/index.php/home3/article/view/41/45>. Acesso em: 19 set. 2024.
- AURICCHIO, Paulo. **Primatas do Brasil**. São Paulo: Terra Brasilis, 1995.
- BILLAH, Massum *et al.* Real-time goat face recognition using convolutional neural network. **Computers and Electronics in Agriculture**, v. 194, p. 106730, mar. 2022. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0168169922000473>. Acesso em: 6 set. 2024.
- CHIARELLI, A.B. **Taxonomic atlas of living primates**. Academic Press, 1972. 363 p.
- CORDEIRO *et al.* **Reconhecimento Facial e suas aplicações**. 2024. 41 f. Projeto de Sistemas – Instituto Federal de Educação, Ciência e Tecnologia de São Paulo, Cubatão. Disponível em: [https://portais.ifsp.edu.br/cbt/images/Documentos/2023/CTII/Grupo01\\_ReconhecimentoFacial1.pdf](https://portais.ifsp.edu.br/cbt/images/Documentos/2023/CTII/Grupo01_ReconhecimentoFacial1.pdf). Acesso em: 22 set. 2024.
- CROUSE, David *et al.* LemurFaceID: a face recognition system to facilitate individual identification of lêmures. **BMC Zoology**, [s.l.], v. 2, n. 1, p. 1-14, fev. 2017. Disponível em: <https://link.springer.com/article/10.1186/s40850-016-0011-9#citeas>. Acesso em: 5 set. 2024.
- DEB, Debayan *et al.* Face Recognition: Primates in the wild. In: **2018 IEEE 9th International Conference on Biometrics: Theory, Applications and Systems (BTAS)**, Redondo Beach, v. 9, n. 1, p. 1-10, abr. 2018. Disponível em: <https://ieeexplore.ieee.org/abstract/document/8698538>. Acesso em: 6 set. 2024.
- FURB. **Projeto Bugio**. [2001?]. Disponível em: <https://www.furb.br/web/1704/noticias/arquivo/2021/03/projeto-bugio-comemora-30-anos-reconhecido-como-referencia/8600>. Acesso em: 16 set. 2024.

GOLDBARG, Mateus Arnaud Santos de Sousa. **Compressão Consciente de Modelos de Redes Neurais Profundas Baseada em Poda Seguida de Quantização**. 2024. 62 f. Dissertação (Mestrado em Engenharia Elétrica de Computação) – Curso de Pós-Graduação em Engenharia Elétrica e de Computação, Universidade Federal do Rio Grande do Norte, Natal. Disponível em: [https://repositorio.ufrn.br/bitstream/123456789/58271/1/Compressaoconscientemodelos\\_Goldbarg\\_2024.pdf](https://repositorio.ufrn.br/bitstream/123456789/58271/1/Compressaoconscientemodelos_Goldbarg_2024.pdf). Acesso em: 22 set. 2024.

GREGORIN, Renato. Taxonomia e variação geográfica das espécies do gênero *Alouatta* Lacépède (Primates, Atelidade) no Brasil. **Revista brasileira de zoologia**, [s.l.], v. 23, 15 mai. 2006. Disponível em: <https://www.scielo.br/j/rbzool/a/TMzTcKJS6rFYnqNjKrsFNRz/?lang=pt>. Acesso em: 20 set. 2024.

GU, Jiuxiang *et al.* **Recent Advances in Convolutional Neural Networks**. arXiv. 2017. Disponível em: <https://arxiv.org/abs/1512.07108v6>. Acesso em: 3 dez. 2024.

GUO, Songtao *et al.* Automatic Identification of Individual Primates with Deep Learning Techniques. **iScience**, [s.l.], v. 23, n. 8, p. 1-32, ago. 2020. Disponível em: [https://www.cell.com/iscience/fulltext/S2589-0042\(20\)30602-7](https://www.cell.com/iscience/fulltext/S2589-0042(20)30602-7). Acesso em: 6 set. 2024.

HIRANO, Z. M. B. *et al.* Morphology of epidermal glands responsible for release of colored secretions in *Alouatta guariba clamitans*. **Laboratory Primates Newsletter**, [s.l.], v. 42, n. 2, p. 4-6, 2003. Disponível em: <https://www.brown.edu/Research/Primate/lpn42-2.html>. Acesso em: 16 set. 2024.

INSTITUTO Chico Mendes de Conservação da Biodiversidade – ICMBio. **Avaliação do Risco de Extinção de *Alouatta guariba clamitans* (Cabrera, 1940) no Brasil**. 2012. Disponível em: [https://www.gov.br/icmbio/pt-br/assuntos/centros-de-pesquisa/primatas-brasileiros/arquivos/fichas\\_primatas/ATELIDAE/ficha\\_alouatta\\_guariba\\_clamitans.pdf](https://www.gov.br/icmbio/pt-br/assuntos/centros-de-pesquisa/primatas-brasileiros/arquivos/fichas_primatas/ATELIDAE/ficha_alouatta_guariba_clamitans.pdf). Acesso em: 17 set. 2024.

JUNIOR, Guanís de Barros Vilela *et al.* Métricas utilizadas para avaliar a eficiência de classificadores em algoritmos inteligentes. **Centro de Pesquisas Avançadas em Qualidade de Vida**, v. 14, n. 2, p. 1, jan. 2022. Disponível em: <https://revista.cpaqv.org/index.php/CPAQV/article/view/933/version/811>. Acesso em: 4 dez. 2024.

KEMERICH, Anastácio; MARTINS, Mirkos Ortiz. **Reconhecimento facial utilizando OpenCV na segurança pública**. 2021. Ciência da Computação - Universidade Franciscana, Santa Maria. Disponível em: <https://tfonline.lapinf.ufn.edu.br/media/midias/AnastacioKemerich.pdf>. Acesso em: 4 dez. 2024.

LECUN, Yann; BENGIO, Y.; HINTON, Geoffrey. Deep learning. **Nature**, v. 521, n. 7553, p. 436–444, 2015. Disponível em: [https://www.researchgate.net/publication/277411157\\_Deep\\_Learning](https://www.researchgate.net/publication/277411157_Deep_Learning). Acesso em: 27 nov. 2024.

LI, Xiaopeng *et al.* **SheepFaceNet: A Speed-Accuracy Balanced Model for Sheep Face Recognition**, Xianyang, v. 13, n. 12, 9 jun. 2023. Disponível em: <https://www.mdpi.com/2076-2615/13/12/1930>. Acesso em: 5 set. 2024.

LIMA, Isaías *et al.* **Inteligência artificial**. Rio de Janeiro: GEN LTC, 2014. Disponível em: <https://bu.furb.br/consulta/portalConsulta/recuperaMfnCompleto.php?menu=rapida&CdMFN=613368>. Acesso em: 19 set. 2024.

MACHADO, A. Z. *et al.* Biometria de bugios-ruivos (*Alouatta guariba clamitans*) de vida livre no município de Santa Maria, RS. p. 729. **Caderno de resumos do XXX Congresso Brasileiro de Zoologia**. Sociedade Brasileira de Zoologia, Porto Alegre, 2014. Acesso em: 17 set. 2024.

MARQUES, Eduarda Almeida Leão. **Estudo sobre Redes Neurais de Aprendizado Profundo com Aplicações em Classificação de Imagens**. 2016. 58 f. Relatório Final de Monografia (Bacharelado em Estatística) – Departamento de Estatística, Universidade de Brasília, Brasília. Disponível em: [https://bdm.unb.br/bitstream/10483/15147/1/2016\\_EduardaAlmeidaLeaoMarques.pdf](https://bdm.unb.br/bitstream/10483/15147/1/2016_EduardaAlmeidaLeaoMarques.pdf). Acesso em: 21 set. 2024.

MASCHIO, Minéia. **Reconhecimento facial de bugios-ruivos por meio de modelos de aprendizado de máquina**. 2023. 21 f. Trabalho de Conclusão de Curso (Bacharelado em Ciência da Computação) – Departamento de Sistemas e Computação, Universidade Regional de Blumenau, Blumenau. Disponível em: [https://www.furb.br/dsc/arquivos/tccs/monografias/2022\\_1\\_maik-henrique-carminati\\_monografia.pdf](https://www.furb.br/dsc/arquivos/tccs/monografias/2022_1_maik-henrique-carminati_monografia.pdf). Acesso em: 12 set. 2024.

MCCULLOCH, Warren; PITTS, Walter. **A logical calculus of the ideas imminent in nervous activity**. Bulletin of Mathematical Biophysics, Chicago, v. 5, p. 115-33, 1943. Disponível em: <https://home.csulb.edu/~cwallis/382/readings/482/mcculloch.logical.calculus.ideas.1943.pdf>. Acesso em: 21 set. 2024.

PAULET *et al.* Deep learning for automatic facial detection and recognition in Japanese macaques: illuminating social networks. **Primates**, [s.l.], v. 65, p. 265–279, 17 mai. 2024. Disponível em: <https://link.springer.com/article/10.1007/s10329-024-01137-5>. Acesso em: 7 set. 2024.

PIRES, Ricardo Lucas. **Visão computacional aplicada na gestão da tecnologia da informação**. São Paulo, 2023. 12f. Trabalho de conclusão de curso. (Curso superior de tecnologia em gestão da Tecnologia da Informação). Faculdade de Tecnologia de Assis, Assis. Disponível em: <https://ric.cps.sp.gov.br/bitstream/123456789/15850/1/VISOCO~1.PDF>. Acesso em: 28 set. 2024.

REDFORD, K. H.; EISENBERG, J. F. **Mammals of the Neotropics, volume 2, the southern cone: Chile, Argentina, Uruguay, Paraguay**. The University of Chicago Press, Chicago, 1992. 430 p.

RUSSELL, Stuart J; NORVIG, Peter Coautor. **Inteligência artificial: uma abordagem moderna**. Rio de Janeiro: GEN LTC, 2022. Disponível em: <https://bu.furb.br/consulta/portalConsulta/recuperaMfnCompleto.php?menu=rapida&CdMFN=615728>. Acesso em: 19 set. 2024.

SARTORE, Joel. **Bugios**. [2022]. Disponível em: <https://www.nationalgeographicbrasil.com/animais/bugios>. Acesso em: 29 set. 2024.

SHARIFANI, Koosha; AMINI, Mahyar. Machine Learning and Deep Learning: A Review of Methods and Applications. **World Information Technology and Engineering Journal**, [s.l.], v. 10, n. 7, p. 3897-3904, 25 mai. 2023. Disponível em: [https://papers.ssrn.com/sol3/papers.cfm?abstract\\_id=4458723](https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4458723). Acesso em: 22 set. 2024.

SILVEIRA, Filipe F. **Fauna Digital do Rio Grande do Sul**, 2018. Bird and Mammal Evolution, Systematics and Ecology Lab – UFRGS. Disponível em: <https://www.ufrgs.br/faunadigitalrs/mamiferos/ordem-primates/familia-atelidae/bugio-ruivo-alouatta-guariba-clamitans>. Acesso em: 22 set. 2024.

VARGAS, Ana Caroline Gomes; CARVALHO, Aline Marins Paes; VASCONCELOS, Cristina Nader. **Um estudo sobre Redes Neurais Convolucionais e sua aplicação em detecção de pedestres**. 2016, Instituto de Computação, Universidade Federal Fluminense, Niterói. Disponível em: <http://gibis.unifesp.br/sibgrapi16/e proceedings/wuw/7.pdf>. Acesso em: 27 nov. 2024.