

CURSO DE CIÊNCIA DA COMPUTAÇÃO – TCC (RES_020/2016 – 2024_2)		
() PRÉ-PROJETO	(X) PROJETO	ANO/SEMESTRE: 2024/2

AUTOMATIZANDO O PRÉ-DIAGNÓSTICO DE DOENÇAS AUDITIVAS: UMA PLATAFORMA DE TELEMEDICINA COM APRENDIZADO DE MÁQUINA E IMAGENS OTOSCÓPICAS

Bruna Lauschner

Prof. Aurélio Faustino Hoppe – Orientador

1 INTRODUÇÃO

A saúde auditiva é um componente fundamental do bem-estar humano, porém a prevalência de doenças auditivas é significativa em todas as faixas etárias e regiões do mundo. De acordo com o primeiro Relatório Mundial sobre Audição da Organização Mundial da Saúde (2011, p. 8, tradução nossa), "entre os países de baixa renda, cerca de 78% têm menos de um especialista em ouvido, nariz e garganta por milhão de habitantes". Isso demonstra como o acesso a cuidados especializados permanece limitado, especialmente em países em desenvolvimento. No estudo de Powell *et al.* (2019), descobriu-se que pacientes de áreas rurais, onde há menos profissionais capacitados, enfrentam atrasos significativos para obter acesso a consultas e tratamentos, fazendo com que essas disparidades geográficas contribuam para uma menor qualidade do cuidado auditivo.

O relatório da Organização Mundial da Saúde (2011), também destaca a importância da prevenção da perda auditiva, especialmente entre as crianças, no qual quase 60% dos casos de surdez em qualquer grau poderiam ser prevenidos com intervenções precoces, como o tratamento adequado dos casos de Otite Média (OM). De acordo com Jensen, Koch e Homøe. (2013), a Otite Média Crônica Supurada (OMCS), é uma das principais causas de perda auditiva, afetando entre 65 e 330 milhões de pessoas em países em desenvolvimento, e 91% das crianças com OMCS acabam desenvolvendo perda auditiva permanente superior a 15 dBHL. Esse dado, que reflete apenas um subtipo de otite, subestima a real extensão do problema pois, segundo os autores, esses números ressaltam a recorrência das doenças auditivas na população.

Segundo Falkson e Tadi (2020), para a identificação de patologias auditivas, é realizado um exame chamado de otoscopia, que permite a visualização detalhada do ouvido. O médico utiliza um otoscópio, instrumento equipado com um espéculo iluminado e uma lente de aumento, que facilita a inspeção do canal auditivo e da membrana timpânica. Durante o procedimento, o espéculo é inserido no ouvido do paciente para observar características importantes, como a cor, translucidez, presença de cera ou secreções, inflamações e outras anomalias. Falkson e Tadi (2020, tradução nossa) também ressaltam a importância desse exame explicando que “o diagnóstico atrasado de diversas patologias do ouvido podem facilitar a progressão de condições mais sérias” exemplificando com o caso de uma Otite Média Aguda (OMA) não tratada, que pode causar mastoidite, abscessos cerebrais ou meningite. Portanto, de acordo com os autores, a otoscopia desempenha um papel crucial na detecção e tratamento precoce, prevenindo danos permanentes à audição.

Neste contexto, Ibekwe e Fasunla (2020) destacam que a telemedicina emerge como uma abordagem promissora para democratizar o acesso à saúde auditiva, especialmente em áreas remotas ou desfavorecidas, onde a presença de especialistas é limitada. Além disso, segundo os autores, a telemedicina no campo da otorrinolaringologia é promissora e pode ser altamente eficaz, pois, com o auxílio de dispositivos móveis como smartphones e laptops, é possível realizar consultas audiovisuais. Para Ibekwe e Fasunla (2020), essa abordagem facilita o pré-diagnóstico e tratamento de doenças auditivas, permitindo que pacientes consultem especialistas sem a necessidade de deslocamento. Além disso, o uso de plataformas digitais permite armazenar o histórico médico e imagens otoscópicas dos pacientes, facilitando o acompanhamento contínuo e proporcionando um atendimento mais eficiente.

Da mesma forma, segundo Song *et al.* (2023, p. 10, tradução nossa), “sistemas de telemedicina que incorporam tecnologia de Inteligência Artificial (IA) com precisão comparável à de um especialista podem ser benéficos para pacientes em áreas com escassez de especialistas ou para aqueles que têm dificuldade em visitar um hospital”. Assim, a IA pode realizar análises preliminares de imagens otoscópicas, identificando padrões e doenças com rapidez e precisão. Os autores também ressaltam que, embora a acurácia dos diagnósticos possa variar de acordo com o treinamento e a especialização do médico, o uso de técnicas de aprendizado de máquina promove maior consistência e precisão nos resultados. Dessa maneira, pode-se reduzir o risco de erros humanos e padronizar o processo de avaliação. Ao integrar essa triagem automatizada às plataformas de telemedicina, o tempo dos profissionais pode ser mais bem aproveitado, aumentando o alcance e qualidade dos serviços de saúde auditiva.

Diante dessas evidências, este trabalho visa desenvolver uma plataforma web de telemedicina integrada a um modelo de Aprendizado de Máquina que facilite o acesso a um diagnóstico auditivo, potencialize a detecção precoce de doenças auditivas e conecte pacientes a médicos, independentemente de sua localização geográfica.

Nesse contexto, surge a seguinte pergunta de pesquisa: "Como os algoritmos de aprendizado de máquina podem ser treinados e validados para analisar imagens otoscópicas e realizar pré-diagnósticos precisos de doenças auditivas em uma plataforma web de telemedicina, minimizando a intervenção humana e otimizando a qualidade do atendimento em saúde auditiva?"

1.1 OBJETIVOS

O objetivo deste trabalho é disponibilizar uma plataforma de telemedicina com Aprendizado de Máquina para pré-diagnóstico de doenças auditivas a partir de imagens otoscópicas.

Os objetivos específicos são:

- a) identificar e classificar doenças auditivas, como Otite Média e variações, e demais condições, como cerume impactado, a partir de imagens otoscópicas utilizando algoritmos de processamento de imagem e redes neurais artificiais para extrair características e padrões das imagens;
- b) disponibilizar o modelo desenvolvido em uma plataforma online de telemedicina para utilização por médicos especialistas e outros profissionais de saúde, visando auxiliar no pré-diagnóstico e tratamento de doenças auditivas;
- c) avaliar a precisão e eficácia do modelo desenvolvido em diferentes condições de iluminação, ângulos de captura de imagem e variações de características das imagens otoscópicas, comparando os resultados com diagnósticos realizados por especialistas.

2 TRABALHOS CORRELATOS

Nesta seção, apresenta-se uma revisão sistemática da literatura existente sobre a identificação de doenças por imagens otoscópicas e as aplicações existentes de plataformas e aplicativos de telemedicina auditiva. A revisão sistemática, descrita na subseção 2.1, detalha os critérios de busca e seleção dos estudos relevantes. A subseção 2.2 apresenta uma síntese dos trabalhos correlatos, destacando a correlação com o trabalho proposto.

2.1 REVISÃO SISTEMÁTICA

Para realizar a busca por trabalhos correlatos, realizou-se pesquisas pelos portais Litmaps, Science Direct, Google Acadêmico e IEEE Xplore, abrangendo um período de cinco anos, de 2019 a 2024. Conforme demonstra o Quadro 1, foram realizadas buscas por conjuntos de termos relacionados com a pesquisa, como “otoscopia”, “doença”, “ouvido”, “aprendizado de máquina”, “telemedicina”, entre outros. A partir disso, os termos foram traduzidos para o inglês, repetindo as buscas, conforme pode ser observado no Quadro 2.

Quadro 1 – Resultado de buscas por termos contidos em artigos em língua portuguesa

Termos de busca	Litmaps	Science Direct	Google Acadêmico	IEEE Xplore	Total
“otoscopia” + “análise de imagem” + “ouvido”	-	-	2	-	2
“otoscopia” + “diagnóstico de imagem” + “ouvido”	-	-	8	-	8
“otoscopia” + “processamento de imagem” + “ouvido”			1	-	1
“endoscopia” + “análise de imagem” + “ouvido”	-	-	3	-	3
“endoscopia” + “diagnóstico de imagem” + “ouvido”	-	-	14	-	14
“endoscopia” + “processamento de imagem” + “ouvido”	-	-	1	-	1
“aprendizado de máquina” + “doença” + “ouvido”	1	-	239	-	240
“inteligência artificial” + “doença” + “ouvido”	1	-	1.490	-	1.491
“aplicativo” + “celular” + “doenças de ouvido”	-	-	-	-	0
“plataforma” + “web” + “doenças de ouvido”	-	-	2	-	2
“telemedicina” + “doenças de ouvido”	-	-	-	-	0

Fonte: elaborado pela autora.

Quadro 2 – Resultado de buscas por termos contidos em artigos em língua inglesa

Termos de busca	Litmaps	Sciente Direct	Google Acadêmico	IEEE Xplore	Total
“otoscopy” + “image analysis” + “ear”	5	17	240	4	266
“otoscopy” + “image diagnosis” + “ear”	4	10	21	12	47
“otoscopy” + “image processing” + “ear”	5	10	166	12	193
“endoscopy” + “image analysis” + “ear”	-	81	1.170	3	1.254
“endoscopy” + “image diagnosis” + “ear”	3	12	49	2	66
“endoscopy” + “image processing” + “ear”	2	89	1.160	3	1.254
“machine learning” + “disease” + “ear”	9	2.758	19.100	55	21.922
“artificial intelligence” + “disease” + “ear”	8	2.062	17.400	26	19.496
“app” + “smartphone” + “ear diseases”	6	14	121	7	148
“platform” + “web” + “ear diseases”	5	37	254	-	296
“telemedicine” + “ear diseases”	6	36	241	6	289

Fonte: elaborado pela autora.

Inicialmente, realizou-se uma triagem para reduzir o número de artigos de mais de 40 mil para pouco mais de 900 artigos. Esse processo de filtragem levou em consideração a quantidade de citações, assim como a inclusão de referências dentro do texto a temas relacionados a doenças auditivas. Posteriormente, realizou-se a leitura dos títulos e resumos dos artigos, no qual identificou-se que muitos não são relacionados ao tema definido nesse estudo, sendo voltados à outras áreas como veterinária e por esse motivo, foram excluídos. Foram priorizados artigos que abordavam patologias de ouvido conhecidas e que possuíam explicações detalhadas sobre as técnicas aplicadas. A filtragem também incluiu a busca por artigos que descrevessem métodos de diagnóstico por imagem ou que propusessem soluções para conectar pacientes e médicos via telemedicina. Dessa forma, o Quadro 3 apresenta os trabalhos selecionados que seguiram os critérios mencionados.

Quadro 3 – Síntese dos trabalhos correlatos selecionados

Assunto	Filtro	Referência
Automated Classification of the Tympanic Membrane Using a Convolutional Neural Network	“artificial intelligence” AND “disease” AND “ear”	Lee, Choi e Chung (2019)
Otitis media detection using tympanic membrane images with a novel multi-class machine learning algorithm	“machine learning” AND “disease” AND “ear”	Alhudhaif <i>et al.</i> (2021)
OTONet: Deep Neural Network for Precise Otoscopy Image Classification	“otoscopy” AND “image analysis” AND “ear”	Rao <i>et al.</i> (2022)
Automatic detection of tympanic membrane and middle ear infection from oto-endoscopic images via convolutional neural networks	“endoscopy” AND “image diagnosis” AND “ear”	Khan <i>et al.</i> (2020)
Inteligência computacional para auxílio no diagnóstico de alterações nas orelhas externa e média	“otoscopia” AND “processamento de imagem” AND “ouvido”	Clemente (2024)
Automated diagnosis of ear disease using ensemble deep learning with a big otoendoscopy image database	“machine learning” AND “disease” AND “ear”	Cha <i>et al.</i> (2019)
Computer-aided diagnosis of external and middle ear conditions: A machine learning approach	“machine learning” AND “disease” AND “ear”	Viscaino <i>et al.</i> (2020)
An Assistive Role of a Machine Learning Network in Diagnosis of Middle Ear Diseases	“machine learning” AND “disease” AND “ear”	Byun <i>et al.</i> (2021)
Telemedicine for ear diseases with the smartphone otoscopes via WeChat in the COVID-19 era	“telemedicine” AND “ear diseases”	Dai <i>et al.</i> (2021)
Smartphone-based artificial intelligence using a transfer learning algorithm for the detection and diagnosis of middle ear diseases: A retrospective deep learning study	“app” AND “smartphone” AND “ear diseases”	Chen <i>et al.</i> (2022)
Application of Smartphone Otolaryngoscope in Telemedicine in Rural Medical Consortium in Eastern China in the COVID-19 Era	“app” AND “smartphone” AND “ear diseases”	Meng <i>et al.</i> (2022)
Efficient and accurate identification of ear diseases using an ensemble deep learning model	“platform” AND “web” AND “ear diseases”	Zeng <i>et al.</i> (2021)

Fonte: elaborado pela autora.

Os trabalhos selecionados demonstram o potencial de tecnologias como AM, análise de imagem e telemedicina para melhorar o diagnóstico e o tratamento de doenças do ouvido. As aplicações variam desde a automação do diagnóstico até a expansão do acesso a cuidados de saúde em áreas remotas. Os trabalhos de Lee,

Choi e Chung (2019), Alhudhaif, Cömert e Polat (2021), Rao *et al.* (2022) e Byun *et al.* (2021) exploram o uso de AM, especialmente Redes Neurais Convolucionais (CNNs, do inglês *Convolutional Neural Networks*), para automatizar a classificação de doenças da membrana timpânica e detectar doenças como a OM a partir de imagens coletadas. Da mesma forma, Khan *et al.* (2020) utilizaram CNNs, mas focaram na detecção automática da membrana timpânica e infecção do ouvido médio em imagens otoendoscópicas. Viscaino *et al.* (2020) propuseram o uso de diferentes arquiteturas de AM, como *Support Vector Machine* (SVM), *K-Nearest Neighbor* (KNN) e Árvores de Decisão para criar um modelo preditivo de diferentes condições do ouvido antes da avaliação por especialistas.

Além disso, Clemente (2024), Zeng *et al.* (2021) e Chen *et al.* (2022) contribuíram com investigações sobre a aplicação da IA na identificação de alterações auditivas. Clemente (2024) investigou o uso da inteligência computacional e explorou o desempenho de diversas arquiteturas de CNN para classificar condições da orelha externa e média, enquanto Zeng *et al.* (2021) e Chen *et al.* (2022) desenvolveram modelos de *Deep Learning* (DL) para diagnósticos de doenças e condições de ouvido com eficiência e precisão. Zeng *et al.* (2021) focaram no diagnóstico em tempo real utilizando uma plataforma web e Chen *et al.* (2022) realizou uma abordagem baseada em dispositivos móveis.

Por fim, Dai *et al.* (2021) e Meng *et al.* (2022) centraram-se nas aplicações de telemedicina e dispositivos móveis. Dai *et al.* (2021) utilizaram otoscópios de smartphone via WeChat para telemedicina em doenças do ouvido, particularmente no contexto da pandemia de COVID-19. Meng *et al.* (2022) analisaram o uso de otoscópios de smartphone em áreas rurais da China durante a pandemia de COVID-19, comprovando o aumento na satisfação dos pacientes. Chen *et al.* (2022) também se destacam na área de telemedicina com a adaptação do seu modelo para uma aplicação de smartphone via *transfer learning*, permitindo o acesso a pacientes em locais remotos.

2.2 SÍNTESE DOS TRABALHOS CORRELATOS

Nesta seção são apresentados os trabalhos com características semelhantes aos do estudo proposto. O Quadro 4 apresenta o trabalho de Alhudhaif, Cömert e Polat (2021), no qual desenvolveu-se um algoritmo de CNN para classificação dos subtipos da doença OM em imagens otoscópicas da membrana timpânica.

Quadro 4 – Otitis media detection using tympanic membrane images with a novel multi-class machine learning algorithm

Referência	Alhudhaif, Cömert e Polat (2021)
Objetivos	Desenvolvimento de um algoritmo de detecção de Otite Média e seus subtipos para tornar o diagnóstico mais eficaz e rápido.
Principais funcionalidades	Reconhecimento e classificação de doenças pré-categorizadas.
Ferramentas de desenvolvimento	Modelo de Redes Neurais Convolucionais ponta a ponta, com uma função de ativação Softmax; Técnica de blocos residuais aplicadas como camadas no segundo e terceiro estágio do treinamento, que melhoram a capacidade da rede de aprender e generalizar a partir de dados complexos; Módulo de atenção <i>Convolutional Block Attention Module</i> (CBAM) também aplicadas nas camadas do segundo e terceiro estágio do treinamento para identificação de características mais importantes; Técnica de <i>Hypercolumn</i> no treinamento do modelo para capturar informações de diferentes camadas e combiná-las para obter uma representação mais detalhada para ser usada como entrada na camada final.
Resultados e conclusões	Foram realizados quatro experimentos, sendo que em todos, dividiu-se o <i>dataset</i> na proporção 80% para treinamento e 20% para testes. No primeiro experimento, o <i>dataset</i> foi composto de 956 imagens divididas em cinco classes, que obteve uma precisão de 82.81%, indicando um desempenho satisfatório para 3 classes (normal, OMA e cera de ouvido) mas teve dificuldades para classificar as demais. No segundo experimento, excluiu-se a classe “outros”, que obtinha diferentes tipos de doenças, resultando em um <i>dataset</i> de 857 imagens, divididas em 4 classes. Houve melhoria geral no desempenho do modelo, atingindo precisão de 86.63% e apresentando maior dificuldade para a classe OMCS devido ao número limitado de amostras. No terceiro experimento, aplicou-se <i>data augmentation</i> em todas as amostras iniciais, novamente usando 5 classes, resultando em um melhor desempenho e atingindo precisão de 92.19%. No quarto experimento, com o mesmo <i>dataset</i> aumentado do experimento anterior, novamente realizou-se a exclusão da classe “outros”, gerando uma precisão de 98.26%. Assim, o modelo proposto superou os modelos CNN pré-treinados já existentes e os avanços feitos ajudaram a melhorar significativamente o diagnóstico automático de doenças de OM.

Fonte: elaborado pela autora.

No Quadro 4 é sintetizado o trabalho de Alhudhaif, Cömert e Polat (2021), no qual desenvolveram uma solução para o diagnóstico de OM com o uso de um modelo próprio baseado em CNN. O sistema integra diversas técnicas de processamento de imagens, como o módulo de atenção *Convolutional Block Attention Module* (CBAM), blocos residuais e *Hypercolumn*, que aprimoram a acurácia na detecção de OM em imagens otoscópicas. Segundo os autores, a solução automatiza parte do processo clínico, diminuindo erros e oferecendo suporte ao processo de

tomada de decisão. No entanto, vale destacar que esse trabalho focou no desenvolvimento do modelo de aprendizagem de máquina e por isso, não possui interface de comunicação com usuário.

O trabalho de Alhudhaif, Cömert e Polat (2021) servirá de base ao proposto devido à clareza nas explicações das metodologias, técnicas e configurações aplicadas, visto que foi construído um modelo de AM próprio. Além disso, o trabalho servirá de inspiração devido aos diferentes testes realizados no momento da validação do modelo de AM, permitindo uma análise mais detalhada dos resultados obtidos.

No Quadro 5, é descrito o trabalho de Khan *et al.* (2020), ao qual utilizaram CNNs para classificação automática de infecções na membrana timpânica e no ouvido médio a partir de imagens otoscópicas.

Quadro 5 – Automatic detection of tympanic membrane and middle ear infection from oto-endoscopic images via convolutional neural networks

Referência	Khan <i>et al.</i> (2020)
Objetivos	Desenvolvimento de uma interface web que utilize um modelo de CNN próprio para classificação de imagens de ouvido nas categorias: normal, Otite Média Crônica (OMC) com perfuração da membrana timpânica e Otite Média com Efusão (OME).
Principais funcionalidades	Reconhecimento e classificação de doenças pré-categorizadas e disponibilização de uma interface web para diagnósticos.
Ferramentas de desenvolvimento	Técnica de aprendizado por transferência com modelos pré-treinados de Redes Neurais Convolucionais que realizam classificação específica. Realizou-se um ajuste fino nas camadas finais, como substituição da camada de saída por uma camada <i>softmax</i> , utilização de otimização com <i>Adam optimizer</i> e regularização, com <i>data augmentation</i> . Técnica de <i>Class Activation Mapping</i> (CAM), mais especificamente a extensão Grad-CAM, na camada final do modelo para gerar um mapa de ativação com as áreas mais relevantes. Utilizado para validação das previsões realizadas.
Resultados e conclusões	O <i>dataset</i> final é composto de 2484 imagens endoscópicas da membrana timpânica, classificadas por especialistas em três classes. Dos modelos treinados e testados com o <i>dataset</i> , o modelo DenseNet161 apresentou os melhores resultados, com precisão de 95%. Então, foi feita a análise qualitativa das imagens geradas com mapa de ativação que confirmou as previsões sendo geradas corretamente. Por fim, foi realizado um teste com especialistas, que alcançou 74% de acurácia média, com variação entre 40% e 93% entre os médicos. Em contrapartida, o modelo atingiu a acurácia de 87%. Assim, comprovando um potencial significativo para aplicabilidade prática por pacientes e otorrinolaringologistas no dia a dia.

Fonte: elaborado pela autora.

No Quadro 5 encontra-se uma síntese referente ao trabalho de Khan *et al.* (2020), que apresenta uma solução para a detecção e classificação automática de infecções na membrana timpânica e no ouvido médio, também utilizando redes neurais convolucionais. O estudo disponibiliza uma interface web para usuários para permitir a classificação automática de imagens otoscópicas em três categorias: normal, OMC com perfuração da membrana timpânica e OME. Além disso, o sistema inclui uma *Class Activation Mapping* (CAM), que oferece uma visualização clara das áreas relevantes usadas para predição. O uso dessa técnica proporciona maior confiabilidade aos resultados ao garantir que o modelo irá considerar os mesmos pontos de vista que médicos. Apesar da solução ter potencial para ser aplicada em cenários clínicos reais, seus bons resultados podem ter sido impactados pela baixa diversidade de doenças exploradas.

Este trabalho (Khan *et al.*, 2020) foi selecionado devido à implementação de uma plataforma web e integração da mesma à um modelo de AM, permitindo uma interação com o usuário independente da sua localização e assim, alinhando-se à proposta do presente trabalho de permitir o acesso ao diagnóstico via telemedicina. Por fim, o Quadro 6 apresenta o trabalho de Chen *et al.* (2022), que desenvolveram um modelo de DL adaptado para aplicativos de smartphones para detecção e diagnóstico de doenças auditivas

Quadro 6 – Smartphone-based artificial intelligence using a transfer learning algorithm for the detection and diagnosis of middle ear diseases: A retrospective deep learning study

Referência	Chen <i>et al.</i> (2022)
Objetivos	Desenvolvimento de um modelo de detecção e diagnóstico de doenças do ouvido médio e transformação do modelo treinado para um aplicativo de dispositivos móveis.
Principais funcionalidades	Reconhecimento e classificação de doenças e condições pré-categorizadas e disponibilização de um aplicativo <i>mobile</i> para diagnósticos.
Ferramentas de desenvolvimento	Diferentes modelos de Redes Neurais Convolucionais com arquiteturas padrões de classificação, com técnica de inicialização de pesos pré-treinados com ImageNet. Realizou-se um ajuste fino para 50 épocas e otimização com <i>Stochastic Gradient Descent</i> (SGD). Técnica de transferência do melhor modelo pré-treinado para inicialização dos pesos das redes CNN leves, usadas em aplicativos móveis. Técnica de <i>Class Activation Mapping</i> (CAM), aplicada na camada final do modelo, onde, para cada imagem de tímpano, o CAM é gerado e sobreposto à imagem original gerando um mapa de ativação com as áreas mais relevantes. Utilizado para validação das previsões realizadas.

Resultados e conclusões	O <i>dataset</i> , após todas as exclusões, ficou composto por 2.161 imagens do tímpano, separadas em 10 classes diferentes. Após aplicação de <i>data augmentation</i> , o <i>dataset</i> foi ampliado para 10465 imagens. Os testes se deram através do treinamento e validação de diferentes modelos treinados. Assim, o modelo InceptionV3 apresentou a maior acurácia durante a validação (98%) e foi selecionado para o aprendizado por transferência. Finalmente, o desempenho dos modelos leves foi avaliado e o modelo que apresentou a melhor acurácia foi o MobileNetV2 (TL), com 97.6%. Por fim, realizou-se um teste para comparar a precisão do aplicativo e a precisão de especialistas, em que o modelo teve um desempenho comparável ao dos especialistas em otorrinolaringologia. Isso, combinado ao fato de possuir uma interface amigável e acessível ao usuário comprovou a sua utilidade.
-------------------------	---

Fonte: elaborado pela autora.

No Quadro 6, encontra-se a síntese do trabalho de Chen *et al.* (2022), que propuseram uma solução baseada em IA para a detecção e classificação de doenças do ouvido médio, como OM e OME. Utilizou-se um modelo baseado em CNN, que realiza a classificação de dez diferentes doenças e condições. Destaca-se o processo de adaptação do modelo para uso em dispositivos móveis, oferecendo uma interface amigável e desempenho superior ao de médicos generalistas e residentes em testes de diagnóstico. A solução também inclui um mapa de ativação por classes para visualizar as áreas de interesse, aumentando a confiabilidade das predições. No entanto, o uso de dispositivos móveis pode gerar algumas limitações na capacidade de processamento de imagens em aparelhos mais simples.

Este trabalho foi escolhido tendo em vista a sua preocupação com a inclusão dos modelos de AM na telemedicina. Por causa disso, o foco em modelos e técnicas mais leves, projetados para funcionar bem em dispositivos de menor capacidade de processamento, serve como inspiração para o proposto trabalho para a implementação de modelos que sejam leves e ao mesmo tempo performáticos.

3 PROPOSTA DA PLATAFORMA

Esta seção apresenta a justificativa para o desenvolvimento deste trabalho, que tem como objetivo criar uma plataforma web de telemedicina equipada com um modelo de AM, capaz de realizar pré-diagnóstico de doenças auditivas a partir de imagens otoscópicas. A metodologia adotada para o desenvolvimento da plataforma e do modelo também serão detalhadas.

3.1 JUSTIFICATIVA

No Quadro 7 é possível observar as principais características de cada trabalho correlato apresentado, onde as colunas descrevem os trabalhos e as linhas, as características. Com elas, pode-se entender como serão solucionados os problemas propostos por este trabalho.

Quadro 7 – Comparativo dos trabalhos correlatos

Trabalhos correlatos Características	Alhudhaif, Cömert e Polat (2021)	Khan <i>et al.</i> (2020)	Chen <i>et al.</i> (2022)
Doenças/condições que tenta identificar/categorizar	Otite Média Aguda, Otite Média Crônica Supurativa, Cera de ouvido, Otite Externa, Tubo de ventilação, Corpo estranho, Pseudomembrana e Timpanosclerose	Otite Média Crônica com Perfuração Timpânica e Otite Média com Efusão	Otite Média Aguda, Miringite Aguda, Otite Média Crônica Supurativa, Otite Média com Derrame, Perfuração Timpânica, Cerúmen em excesso, Tubo de ventilação, Retração do tímpano e Otomicose
Tipo de interface com usuário	Não possui	Plataforma web	Aplicativo de dispositivo móvel
Intuito do modelo	Melhorar a precisão dos diagnósticos clínicos realizados	Realizar diagnósticos via telemedicina	Realizar diagnósticos via telemedicina
Modelo de aprendizado de máquina	Redes Neurais Convolucionais	Redes Neurais Convolucionais	Redes Neurais Convolucionais
Tipos de arquiteturas de redes utilizadas no treinamento do modelo	Foi criado um modelo próprio	ResNet, DenseNet, VGGNet, SENet, InceptionV3 e GoogleNet	VGG16, VGG19, Xception, InceptionV3, NASNetLarge e ResNet50
Número de imagens do dataset	956	2.484	2.820
Resultados obtidos	Acurácia: 98.26%; Sensibilidade: 97.68%; Especificidade: 99.30%	F1 Score: 95.1%; Acurácia: 94.9%; Sensibilidade: 95%; Precisão: 95.2%	Acurácia: 97.6%

Fonte: elaborado pela autora.

Conforme pode ser observado no Quadro 7, o estudo de Alhudhaif, Cömert e Polat (2021) abrangeu diversas condições auditivas. Contudo, uma análise mais detalhada do *dataset* utilizado revela que os autores concentraram seus esforços principalmente na identificação de OMA (119 imagens), OMCS (63 imagens) e cera de ouvido (140 imagens), enquanto outras condições foram representadas por apenas 99 imagens. Os autores desenvolveram um modelo próprio, com técnicas como módulo de atenção, blocos residuais e *Hypercolumn*, que combinados permitem o modelo extrair e utilizar o máximo de características mais relevantes nas imagens. Essa arquitetura forneceu excelentes resultados de acurácia (98.26%) em comparação com arquiteturas CNNs pré-treinados (entre 80.23% e 84.88%). No entanto, o ótimo desempenho pode ser atribuído ao pequeno tamanho do *dataset*, o que indica que o modelo pode não ter sido treinado adequadamente. Além disso, o trabalho não possui uma interface de usuário, restringindo sua aplicação prática à aprimorar a precisão dos diagnósticos realizados em clínicas médicas e, por isso, sua aplicabilidade é limitada em contextos de telemedicina.

Por outro lado, Khan *et al.* (2020) implementaram uma interface com o usuário em um sistema web, permitindo que o sistema seja aplicado na telemedicina já que retorna um *feedback* com o diagnóstico. Utilizando arquiteturas mais conhecidas, esse trabalho focou em condições mais específicas e comuns em pacientes, como OMC, OME e perfurações timpânicas. Esse artigo se destaca por utilizar um número maior de imagens no *dataset* (2.484) em comparação com o anterior, demonstrando a robustez do modelo em uma base de dados maior. Após os treinamentos de todos os modelos, o escolhido pelos autores foi o DenseNet161, que após sofrer algumas modificações em sua parametrização, resultou em uma acurácia ótima (94.9%), esse valor pode estar relacionado a um dos limitadores do estudo, que é a baixa diversidade de condições auditivas utilizadas. Outro ponto de destaque é a comparação das médias de acurácia e tempo de avaliação entre o modelo (87% em 4 segundos) e médicos convidados (74% em 17 minutos), demonstrando a eficácia do uso de IA nesse contexto.

O estudo de Chen *et al.* (2022) também introduziu uma interface com o usuário que retorna o diagnóstico automaticamente, se tornando aplicável para a telemedicina, similar ao trabalho de Khan *et al.* (2020). No entanto, neste trabalho, a interação com o usuário ocorre via aplicativo de smartphone, que recebeu o modelo pré-treinado através da biblioteca Core ML Tools e realiza a classificação da imagem de entrada de acordo com a probabilidade calculada. Chen *et al.* (2022) utilizaram um conjunto de dados com 2820 imagens, além de incluir uma variedade de condições auditivas não utilizadas pelos outros estudos, como Otite Média com Derrame (OMD) e Otomicose, o que fornece uma maior abrangência ao modelo. Para a construção do modelo, os autores aplicaram diferentes arquiteturas de CNN, considerando também os modelos mais leves e performáticos para aplicações mobile. Assim, os melhores modelos foram o InceptionV3, com acurácia de 98%, e o modelo MobileNetV2 (TL), com acurácia de 97,6%.

A análise comparativa desses trabalhos demonstra que, apesar dos bons resultados obtidos, ainda há lacunas a serem preenchidas. O trabalho proposto se diferencia pois une as funcionalidades já presentes em Khan *et al.* (2020) e Chen *et al.* (2022), como a interface com o usuário e o retorno de diagnósticos, mas com o objetivo de expandir o uso de uma plataforma web de telemedicina totalmente integrada, voltada para um público mais amplo. Essa abordagem é crucial para garantir que pessoas de diferentes faixas etárias e níveis socioeconômicos possam acessar facilmente os serviços de saúde auditiva, facilitando o acesso ao diagnóstico e tratamento. Além disso, ao incorporar técnicas avançadas de AM, pode-se aprimorar a precisão e a eficiência, garantindo uma alta taxa de sucesso nos diagnósticos realizados. Portanto, ao integrar o modelo de AM a uma plataforma web, será possível aprimorá-lo continuamente com base nos novos dados e no *feedback* dos usuários, melhorando cada vez mais o modelo.

3.2 METODOLOGIA

O trabalho será desenvolvido em duas partes, sendo elas o desenvolvimento da aplicação web e o desenvolvimento do modelo de aprendizado de máquina. Para a aplicação web, será observado as seguintes etapas:

- a) levantamento bibliográfico: estudar os assuntos relacionados às principais doenças auditivas, aprendizado de máquina e trabalhos correlatos;
- b) elicitação de requisitos da aplicação web: baseando-se nas informações da etapa anterior, elicitar os requisitos propostos para a aplicação;
- c) especificação: utilizar a ferramenta de diagramação *Enterprise Architect* (EA) para elaborar os diagramas de caso de uso e de atividades de acordo com a *Unified Modeling Language* (UML);
- d) desenvolvimento da plataforma web: realizar a implementação da plataforma web que integrará o modelo criado com uma interface amigável para upload de imagens e visualização dos resultados, utilizando o micro framework Flask e a biblioteca React;
- e) testes da aplicação web: elaborar testes para validar a usabilidade da aplicação com profissionais de saúde para avaliar a eficácia e satisfação.

Enquanto para o modelo de AM, será observado as seguintes etapas:


- coleta e preparação de dados: coletar imagens otoscópicas e montar uma base de dados obtidas/cedidas junto a projetos já existentes na comunidade acadêmica. No caso das imagens coletadas durante a realização do trabalho será solicitado aos responsáveis a assinatura do Termo de Consentimento Livre e Esclarecido (TCLE);
- pré-processamento de imagens: realizar a correção de imperfeições nas imagens, como ajuste de iluminação, corte e redimensionamento, para garantir a qualidade dos dados utilizados;
- rotulação das imagens: rotular e validar as imagens coletadas a fim de buscar obter a maior eficiência possível nos resultados.
- definição de algoritmos para identificação e classificação de doenças auditivas: pesquisar as técnicas de aprendizado de máquina para classificar automaticamente as doenças auditivas em pacientes;
- desenvolvimento do modelo: realizar a implementação do modelo utilizando a biblioteca OpenCV, a linguagem de programação Python e as bibliotecas Keras e Tensorflow;
- testes e validação do modelo: avaliar o modelo com um conjunto de dados de validação, para garantir a eficiência e assertividade do modelo.

4 REVISÃO BIBLIOGRÁFICA

Nesta seção serão apresentados os conceitos que fundamentam o estudo proposto. Na subseção 4.1 serão abordadas as doenças e condições auditivas, como otites e perfuração timpânica, e o uso da otoscopia para sua detecção. Já a subseção 4.2 trata sobre aprendizado de máquina, se aprofundando no modelo CNN e suas formas de avaliação.

4.1 DOENÇAS E CONDIÇÕES DO OUVIDO E DETECÇÃO COM USO DA OTOSCOPIA

Como aponta Oliveira *et al.* (2011, p. 369, tradução nossa), “as doenças de ouvido são enfermidades que representam um grupo relevante de morbidade”. Condições como otites, perfurações timpânicas e acúmulo de cerúmen afetam uma parcela significativa da população e podem impactar a audição de forma temporária ou permanente. Como afirmam Pujol e Cunha (2016), o ouvido é dividido em três partes principais: o ouvido externo (orelha e canal auditivo), o ouvido médio (tímpano e cavidade timpânica) e o ouvido interno (cóclea e sistema vestibular). Esta divisão é representada na Figura 1, que ilustra a anatomia da orelha, destacando as partes mencionadas e os componentes físicos de cada uma. As otites são classificadas conforme a área afetada: otite externa, otite média e otite interna, comumente conhecida como labirintite.



Fonte: Silva (s.d.).

De acordo com Wipperman (2014, p. 1, tradução nossa), “Otite Externa (OE) é uma condição inflamatória do canal externo da orelha, com ou sem infecção.” Essa condição pode ser subdividida em Otite Externa Aguda (OEA), frequentemente causada por infecções e conhecida como “orelha de nadador”, e Otite Externa Crônica (OEC), geralmente associada a alergias. Já Mansour *et al.* (2018, p. 86, tradução nossa) explicam que a “Otite Média é um grande espectro de doenças” que inclui OMA, OME e OMCS, entre outras diversas variações, devido às diferentes interações que podem existir entre as infecções. A labirintite (otite interna), conforme descrito por Aslam *et al.* (2023), é uma inflamação do labirinto, localizada na parte interna do ouvido, e pode causar sintomas como perda auditiva, desequilíbrio e vertigem.

A perfuração da membrana timpânica, que pode prejudicar a audição e aumentar o risco de infecções, é descrita por Dolhi e Weimer (2023, tradução nossa) como “uma ruptura na membrana timpânica que leva a uma

conexão entre o conduto auditivo externo e o ouvido médio”. Poulton *et al.* (2015, p. 731, tradução nossa) explica que “a ocorrência de cera de ouvido é uma parte importante do funcionamento normal do ouvido”. No entanto, o excesso pode levar a sintomas como “perda de audição temporária, dor de ouvido, coceira, sensação de plenitude, zumbido, odor, drenagem e tontura” (Fullington *et al.*, 2017, p. 2, tradução nossa).

Para o diagnóstico dessas condições, a otoscopia é o principal método utilizado. Wambier *et al.* (2012, p. 24, tradução nossa) descreve a otoscopia como “o exame que permite ao médico avaliar o conduto auditivo e a membrana timpânica, além de diagnosticar enfermidades da orelha externa e da orelha média”. Medeiros (2018) descreve diferentes formas de realizar um exame otoscópico, sendo o mais comum o uso do otoscópio convencional, que magnifica e ilumina o canal auditivo para permitir a visualização direta de inflamações, infecções, corpos estranhos ou perfurações.

A maioria das doenças apresenta sintomas subjetivos, percebidos diretamente pelo paciente, como otalgia (dor de ouvido), perda auditiva, zumbido e sensação de pressão. No entanto, alguns sinais clínicos só podem ser identificados pelo exame otoscópico, sendo essenciais para diferenciar entre os diferentes tipos de otites, garantindo um diagnóstico preciso e um tratamento correto. Conforme explica Melo (2021), “ao observar o tímpano, o examinador deve estar atento à coloração, contornos e presença ou não de perfurações na membrana”. Entre os sinais mais comuns estão o abaulamento (protuberância ou inchaço anormal), a vermelhidão, a opacificação da membrana (aparência esbranquiçada ou nebulosa) e a imobilidade da membrana timpânica, todos indicadores importantes de diferentes tipos de otites.

Para o caso da OEA, pode haver ocorrência de “meato acústico edemaciado, estreitado, úmido, pálido e hipersensível” (Melo, 2021). Já na OMA, o exame pode relevar “abaulamento, opacidade, hiperemia, possível acúmulo de secreção purulenta” (Melo, 2021). Além disso, Melo (2021) afirma que em casos de perfuração timpânica, além do furo visível, pode-se observar uma mobilidade abolida. Em um estudo conduzido por Shaikh *et al.* (2011, p. 825, tradução nossa) com médicos dos EUA, chegou-se a um consenso de que “a presença de abaulamento na membrana timpânica é um sinal patognomônico de OMA”. Por fim, alguns sinais observados são indícios valiosos para identificação de outras condições, como relata Kosminsky e Vasconcelos (2021) ao observar que “a cor esbranquiçada ou amarelada da membrana indica que há pus no ouvido médio”.

4.2 APRENDIZADO DE MÁQUINA

Webb (2020, p.13 *apud* Santaella, 2023), define IA como um sistema capaz de tomar decisões autônomas. Esse sistema possui a habilidade de aprender e se aprimorar com novas experiências, simulando o raciocínio humano. Segundo Shinde e Shah (2018, p. 1, tradução nossa), “IA significa o estudo de “agentes inteligentes”: qualquer dispositivo que percebe seu ambiente e toma ações que maximizam sua probabilidade de atingir com sucesso seus objetivos”. Dentro do campo da IA, o aprendizado de máquina busca desenvolver sistemas capazes de aprender automaticamente por meio de análise de dados (Santaella, 2023). Carvalho *et al.* (2021) explicam que os sistemas de AM aprendem com experiências passadas, através de tarefas de aprendizado preditivas ou descritivas, dependendo do objetivo. Para as tarefas descritivas, destaca-se o diferencial na capacidade da AM fazer descobertas sozinha, por meio de inferências dos dados fornecidos (Santaella, 2023).

A Aprendizagem Profunda (AP, do inglês *Deep Learning*) pode ser definido como uma subárea de AM, que “utiliza algoritmos mais sofisticados de redes neurais”, como detalha Santaella (2023, p. 135). Conforme Kelleher (2019) relata, a abordagem da AP é especialmente útil para a tomada de decisão baseada em dados, principalmente em contextos que envolvem grandes volumes de dados complexos. A importância dessa abordagem é evidenciada em aplicações inovadoras, como a “extração automática de características relevantes por algoritmos de aprendizado de uso geral” (Lecun *et al.*, 2015 *apud* Carvalho *et al.*, 2021, p. 113).

As Redes Neurais Convolucionais, é um dos tipos mais representativos existentes de AP, que vem ganhando destaque em aplicações como reconhecimento facial, veículos autônomos e tratamentos médicos inteligentes (Li *et al.*, 2021). Carvalho *et al.* (2021, p. 114) ressaltam que “as CNNs imitam o processamento de imagens realizado pelo cérebro, onde, a partir de características muito simples, linhas e curvas, são extraídos padrões de crescente complexidade”. Eles também descrevem de forma sucinta a arquitetura de uma CNN, dividida na etapa de extração de características – uso de uma camada para extrair características e outra para manter apenas as mais relevantes – e em outra etapa de análise dos atributos para realizar previsões.

Existem diversos modelos de CNN que atendem a objetivos variados e continuam a evoluir, resultando em novas arquiteturas a cada ano. Como mencionado por Ramaneswaran *et al.* (2021), modelos como VGGNet, ResNet e Inception foram aplicados com sucesso em várias aplicações de imagens médicas. McNeely-White, Beveridge e Draper (2020) explicam que a arquitetura Inception divide o processamento por escala, mescla os resultados e repete esse processo, enquanto a ResNet apresenta um processamento mais simplificado, com um número maior de camadas e passagem de dados entre os níveis.

Segundo Dinga *et al.* (2019, p. 1, tradução nossa), “independente da aplicação, é importante avaliar a qualidade das previsões [de um modelo] em novos dados, não vistos anteriormente”. Algumas das métricas mais conhecidas e frequentemente utilizadas incluem Acurácia, Precisão, Sensibilidade (em inglês, Recall), e Medida

F1 (em inglês, F1 Score). Conforme Walker II (2024?, tradução nossa) menciona, “essas métricas fornecem avaliações quantitativas das capacidades preditivas de um modelo”. O autor também detalha cada uma das métricas: a acurácia mede o número total de acertos do modelo no cenário geral, a precisão avalia a qualidade das previsões positivas, a sensibilidade mede a capacidade do modelo de identificar corretamente as instâncias positivas, e a medida F1 equilibra a precisão e a sensibilidade. Contudo, conforme Dinga *et al.* (2019) ressaltam, não há medida de performance perfeita que se aplique a todas as situações, sendo essencial considerar o que é importante em cada situação.

REFERÊNCIAS

- ALHUDHAIF, Adi; CÖMERT, Zafer; POLAT, Kemal. Otitis media detection using tympanic membrane images with a novel multi-class machine learning algorithm. **PeerJ Computer Science**, [s. l.], v. 7, p. 405-405, 23 fev. 2021. PeerJ. <http://dx.doi.org/10.7717/peerj-cs.405>. Disponível em: <https://peerj.com/articles/cs-405/>. Acesso em: 19 set. 2024.
- ASLAM, Rafi Gutra *et al.* Labyrinthitis: Comprehensive Literature Review of Inner Part Ear Infection. **Medical Profession Journal Of Lampung**, [s. l.], p. 1-9. abr. 2023. Disponível em: <http://www.journalofmedula.com/index.php/medula/article/view/684>. Acesso em: 17 set. 2024.
- BYUN, Hayoung *et al.* An Assistive Role of a Machine Learning Network in Diagnosis of Middle Ear Diseases. **Journal Of Clinical Medicine**, [s. l.], v. 10, n. 15, p. 3198-3198, 21 jul. 2021. MDPI AG. <http://dx.doi.org/10.3390/jcm10153198>. Disponível em: <https://www.mdpi.com/2077-0383/10/15/3198>. Acesso em: 09 set. 2024.
- CARVALHO, André Carlos Ponce de Leon Ferreira *et al.* **Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina**. 2. ed. Rio de Janeiro: LTC, 2021. Disponível em: <https://integrada.minhabiblioteca.com.br/books/9788521637509>. Acesso em: 27 set. 2024.
- CHA, Dongchul *et al.* Automated diagnosis of ear disease using ensemble deep learning with a big otoendoscopy image database. **Ebiomedicine**, [s. l.], v. 45, p. 606-614, jul. 2019. Elsevier BV. <http://dx.doi.org/10.1016/j.ebiom.2019.06.050>. Disponível em: [https://www.thelancet.com/article/S2352-3964\(19\)30431-1/fulltext](https://www.thelancet.com/article/S2352-3964(19)30431-1/fulltext). Acesso em: 23 set. 2024.
- CHEN, Yen-Chi *et al.* Smartphone-based artificial intelligence using a transfer learning algorithm for the detection and diagnosis of middle ear diseases: a retrospective deep learning study. **eClinicalMedicine**, [s. l.], v. 51, set. 2022. Elsevier BV. <http://dx.doi.org/10.1016/j.eclinm.2022.101543>. Disponível em: [https://www.thelancet.com/journals/eclinm/article/PIIS2589-5370\(22\)00273-5/fulltext](https://www.thelancet.com/journals/eclinm/article/PIIS2589-5370(22)00273-5/fulltext). Acesso em: 19 ago. 2024.
- CLEMENTE, Thallys Augusto. **Inteligência computacional para auxílio no diagnóstico de alterações nas orelhas externa e média**. 2024. 54 f. TCC (Graduação) - Curso de Engenharia de Controle e Automação, Universidade Federal de Ouro Preto, Ouro Preto, 2024. Disponível em: <https://monografias.ufop.br/handle/35400000/6426>. Acesso em: 09 set. 2024.
- DAI, Zhiyong *et al.* Telemedicine for ear diseases with the smartphone otoscopes via WeChat in the COVID-19 era. **American Journal Of Otolaryngology**, [s. l.], v. 42, n. 4, jul. 2021. Elsevier BV. <http://dx.doi.org/10.1016/j.amjoto.2021.102997>. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0196070921000983>. Acesso em: 19 ago. 2024.
- DINGA, Richard *et al.* **Beyond accuracy: Measures for assessing machine learning models, pitfalls and guidelines**. 2019. Disponível em: <https://www.biorxiv.org/content/10.1101/743138v1.full>. Acesso em: 24 set. 2024.
- DOLHI, Nicole; WEIMER, Abram D.. **Tympanic Membrane Perforation**. 2023. Disponível em: <https://www.ncbi.nlm.nih.gov/books/NBK557887/>. Acesso em: 16 set. 2024.
- FALKSON, Samuel R.; TADI, Prasanna. **Otoscopy**. Treasure Island, FL: Statpearls Publishing, 2020. Disponível em: <https://europepmc.org/article/NBK/nbk556090>. Acesso em: 03 out. 2024.
- FULLINGTON, Douglas *et al.* Evaluation of the safety and efficacy of a novel product for the removal of impacted human cerumen. **Bmc Ear, Nose And Throat Disorders**, [s. l.], v. 17, n. 1, 2 jun. 2017. Springer Science and Business Media LLC. <http://dx.doi.org/10.1186/s12901-017-0038-8>. Disponível em: <https://link.springer.com/article/10.1186/s12901-017-0038-8>. Acesso em: 17 set. 2024.
- IBEKWE, Titus Sunday; FASUNLA, Ayotunde James. Telemedicine in otorhinolaryngological practice during COVID-19 pandemic. **Nigerian Medical Journal**, [s. l.], v. 61, n. 3, p. 111-111, maio/jun. 2020. Medknow. http://dx.doi.org/10.4103/nmj.nmj_201_20. Disponível em: https://journals.lww.com/nimj/fulltext/2020/61030/telemedicine_in_otorhinolaryngological_practice.1.aspx. Acesso em: 04 set. 2024.
- JENSEN, Ramon Gordon; KOCH, Anders; HOMØE, Preben. The risk of hearing loss in a population with a high prevalence of chronic suppurative otitis media. **International Journal Of Pediatric Otorhinolaryngology**, [s. l.], v. 77, n. 9, p. 1530-1535, set. 2013. Elsevier BV. <http://dx.doi.org/10.1016/j.ijporl.2013.06.025>. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0165587613003236>. Acesso em: 24 set. 2024.
- KELLEHER, John D. **Deep Learning**. Cambridge, MA: MIT Press, 2019. Disponível em: <https://books.google.com.br/books?hl=pt-BR&lr=&id=b06qDwAAQBAJ>. Acesso em: 24 set. 2024.

KHAN, Mohammad Azam *et al.* Automatic detection of tympanic membrane and middle ear infection from oto-endoscopic images via convolutional neural networks. **Neural Networks**, [s. l.], v. 126, p. 384-394, jun. 2020. Elsevier BV. <http://dx.doi.org/10.1016/j.neunet.2020.03.023>. Disponível em: <https://www.sciencedirect.com/science/article/abs/pii/S0893608020301179>. Acesso em: 19 ago. 2024.

KOSMINSKY, Ellen; VASCONCELOS, Igor. **Otite média aguda na pediatria: sintomas e tratamento**. [s. l.]: Eu Médico Residente, 2024. Disponível em: <https://www.eumedicoresidente.com.br/post/otite-media-aguda-na-pediatria>. Acesso em: 27 set. 2024.

LEE, Je Yeon; CHOI, Seung-Ho; CHUNG, Jong Woo. Automated Classification of the Tympanic Membrane Using a Convolutional Neural Network. **Applied Sciences**, [s. l.], v. 9, n. 9, p. 1827-1827, 2 maio 2019. MDPI AG. <http://dx.doi.org/10.3390/app9091827>. Disponível em: <https://www.mdpi.com/2076-3417/9/9/1827>. Acesso em: 31 ago. 2024.

LI, Zewen *et al.* A Survey of Convolutional Neural Networks: Analysis, Applications, and Prospects. **IEEE Transactions On Neural Networks And Learning Systems**, [s. l.], dez. 2022. p. 6999-7019. Disponível em: <https://ieeexplore.ieee.org/abstract/document/9451544>. Acesso em: 20 ago. 2024.

MANSOUR, Salah *et al.* **Middle Ear Diseases: advances in diagnosis and management**. [s. l.]: Springer, 2018. Disponível em: <https://books.google.com.br/books?hl=pt-BR&lr=&id=2rdmDwAAQBAJ>. Acesso em: 17 set. 2024.

MCNEELY-WHITE, David; BEVERIDGE, J. Ross; DRAPER, Bruce A. Inception and ResNet features are (almost) equivalent. **Cognitive Systems Research**, [s. l.], p. 312-318, jan. 2020. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1389041719305066>. Acesso em: 10 set. 2024.

MEDEIROS, Heraldo José Barroso. **Dispositivo para Documentação de Exame Otoscópico**. 2018. 63 f. Dissertação (Mestrado) - Curso de Mestrado Profissional em Biotecnologia em Saúde Humana e Animal, Universidade Estadual do Ceará, Fortaleza, 2018. Disponível em: <https://ppgbiotec.com/sisac/files/defesas/p0/F851871612773.pdf>. Acesso em: 16 set. 2024.

MELO, Larissa. **Otosopia: aspectos fundamentais**. [s. l.]: Sanarmed, 2021. Disponível em: <https://sanarmed.com/otosopia-aspectos-fundamentais-columnistas/>. Acesso em: 24 set. 2024.

MENG, Xiangming *et al.* Application of Smartphone Otoscope in Telemedicine in Rural Medical Consortium in Eastern China in the COVID-19 Era. **Frontiers In Public Health**, [s. l.], v. 10, 18 maio 2022. Frontiers Media SA. <http://dx.doi.org/10.3389/fpubh.2022.879410>. Disponível em: <https://www.frontiersin.org/journals/public-health/articles/10.3389/fpubh.2022.879410/full>. Acesso em: 19 ago. 2024.

OLIVEIRA, Henrique Fernandes *et al.* DATASUS as a instrument for developing otologic public health policies. **Brazilian Journal Of Otorhinolaryngology**, [s. l.], v. 77, n. 3, p. 369-372, jun. 2011. FapUNIFESP (SciELO). <http://dx.doi.org/10.1590/s1808-86942011000300016>. Disponível em: <https://www.scielo.br/j/bjorl/a/3r6Ch5nBwWC7f5K8BCYyKys/#>. Acesso em: 16 set. 2024.

ORGANIZAÇÃO MUNDIAL DE SAÚDE (OMS). World report on hearing. Geneva: World Health Organization, 2021. Disponível em: <https://iris.who.int/bitstream/handle/10665/339956/9789240021570-eng.pdf>. Acesso em: 03 set. 2024.

POULTON, Skye *et al.* Ear wax management. **Australian Family Physician**, [s. l.], p. 731-734, out. 2015. Disponível em: <https://search.informit.org/doi/abs/10.3316/INFORMIT.525565717724520>. Acesso em: 17 set. 2024.

POWELL, Whitney *et al.* Rural Adult Perspectives on Impact of Hearing Loss and Barriers to Care. **Journal Of Community Health**, [s. l.], p. 668-674, 04 abr. 2019. Disponível em: <https://link.springer.com/article/10.1007/s10900-019-00656-3>. Acesso em: 07 out. 2024.

PUJOL, Rémy; CUNHA, Nuno Trigueiros. **Ouvido**. [s. l.]: Cochlea, 2016. Disponível em: <https://www.cochlea.org/po/ouco/ouvido>. Acesso em: 16 set. 2024.

RAMANESWARAN, S. *et al.* Hybrid Inception v3 XGBoost Model for Acute Lymphoblastic Leukemia Classification. **Computational And Mathematical Methods In Medicine**, [s. l.], v. 2021, n. 999, p. 1-10, 23 jul. 2021. Hindawi Limited. <http://dx.doi.org/10.1155/2021/2577375>. Disponível em: <https://onlinelibrary.wiley.com/doi/full/10.1155/2021/2577375>. Acesso em: 19 set. 2024.

RAO, Divya *et al.* OTONet: deep neural network for precise otoscopy image classification. **IEEE Access**, [s. l.], v. 12, p. 7734-7746, jan. 2024. Institute of Electrical and Electronics Engineers (IEEE). <http://dx.doi.org/10.1109/access.2024.3351668>. Disponível em: <https://ieeexplore.ieee.org/document/10384880>. Acesso em: 31 ago. 2024.

SANTAELLA, Lucia. **A inteligência artificial é inteligente?**. São Paulo: Edições 70, 2023. *E-book*. Disponível em: <https://integrada.minhabiblioteca.com.br/books/9786554270588>. Acesso em: 23 set. 2024.

SHAIKH, Nader *et al.* Oscopic Signs of Otitis Media. **Pediatric Infectious Disease Journal**, [s. l.], v. 30, n. 10, p. 822-826, out. 2011. Ovid Technologies (Wolters Kluwer Health). <http://dx.doi.org/10.1097/inf.0b013e31822e6637>. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/21844828/>. Acesso em: 27 set. 2024.

SHINDE, Pramila P.; SHAH, Seema. A Review of Machine Learning and Deep Learning Applications. In: INTERNATIONAL CONFERENCE ON COMPUTING COMMUNICATION CONTROL AND AUTOMATION (ICCUBE), 4., 2018, Pune. **Proceedings [...]**. Pune: Ieee, 2018. p. 1-6. Disponível em: <https://ieeexplore.ieee.org/abstract/document/8697857>. Acesso em: 24 set. 2024.

SILVA, Michelle Alves da. **Audição**. [s. l.]: InfoEscola. Disponível em: <https://www.infoescola.com/anatomia-humana/audicao/>. Acesso em: 24 nov. 2024.

SONG, Dahye *et al.* Image-Based Artificial Intelligence Technology for Diagnosing Middle Ear Diseases: a systematic review. **Journal Of Clinical Medicine**, [s. l.], v. 12, n. 18, 7 set. 2023. MDPI AG. <http://dx.doi.org/10.3390/jcm12185831>. Disponível em: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10531728/>. Acesso em: 04 set. 2024.

VISCAINO, Michelle *et al.* Computer-aided diagnosis of external and middle ear conditions: a machine learning approach. **Plos One**, [s. l.], v. 15, n. 3, 12 mar. 2020. Public Library of Science (PLOS). <http://dx.doi.org/10.1371/journal.pone.0229226>. Disponível em: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0229226>. Acesso em: 25 set. 2024.

WALKER II, Stephen M.. **F-Score: What are Accuracy, Precision, Recall, and F1 Score?**. [s. l.]: Klu. Disponível em: <https://klu.ai/glossary/accuracy-precision-recall-f1>. Acesso em: 24 set. 2024.

WAMBIER, Guilherme Eduardo *et al.* Otoscopia: exame da orelha. **Jornal Brasileiro de Medicina**, [s. l.], v. 100, n. 1, p. 24-30, jan./mar. 2012. Disponível em: <https://pesquisa.bvsalud.org/portal/resource/pt/lil-654874>. Acesso em: 16 set. 2024.

WIPPERMAN, Jennifer. Otitis Externa. **Primary Care: Clinics in Office Practice**, [s. l.], v. 41, n. 1, p. 1-9, mar. 2014. Elsevier BV. <http://dx.doi.org/10.1016/j.pop.2013.10.001>. Disponível em: [https://www.primarycare.theclinics.com/article/S0095-4543\(13\)00097-3/fulltext](https://www.primarycare.theclinics.com/article/S0095-4543(13)00097-3/fulltext). Acesso em: 17 set. 2024.

ZENG, Xinyu *et al.* Efficient and accurate identification of ear diseases using an ensemble deep learning model. **Scientific Reports**, [s. l.], v. 11, n. 1, 25 maio 2021. Springer Science and Business Media LLC. <http://dx.doi.org/10.1038/s41598-021-90345-w>. Disponível em: <https://www.nature.com/articles/s41598-021-90345-w>. Acesso em: 09 set. 2024.